TableLab：基于本地字段检索的中文表格问答与预测

天津大学机器学习与人工智能 | 课程作业

郑嘉诚

马寅初经济学院　应用经济学

学号：2026209004

2026 年 11 月 1 日

github.com/Karcen/TableLab_DeepSeek

研究问题与系统分工

- 中文问题先检索本地字段与方法说明，DeepSeek API 再生成 JSON 分析方案。
- 用户核对字段和条件后，本机读取原表完成计算与训练。
- 实验比较模型、参数搜索与信息依赖，另检查字段检索排名。

批量模型实验不调用语言模型。生成新问答方案需要联网；真实 API 方案质量尚未评价。

数据与预测任务

任务	记录数	目标	输入
房价	1,460	成交价	面积、质量、年份、地下室、车位、社区。
Adult	32,561	收入类别	年龄、教育、工时、用工类别、职业、婚姻。
NBA	12,844	场均得分	年龄、身高、体重、选秀年份。
学生	1,000	数学成绩	四项背景字段，不输入阅读或写作成绩。
NBA 历史	6,228	下一季得分	三个历史赛季，每季七项信息。

最后一行为另设任务，样本和信息与原 NBA 任务不同。原始文件不改写，历史窗口的筛选原因逐项保存。

内外层验证与信息使用

- 外层三折评价；内层三折选择参数，沿用同一分折规则。
- Adult 按十四个原始预测字段指纹分组分层；NBA 按完整赛季向前验证。
- 插补、编码、缩放及回归目标标准化只在当前训练数据拟合。
- 所有调参只用原训练文件，扩展测试在模型锁定后统一进行。

房价、学生随机分折。原单次划分、前期十三流程与本轮扩展使用不同配置，数值分开报告。

模型与网络结构

- **参照与线性**：常数、无惩罚线性、L2、弹性网、线性 SVM。
- **树模型**：决策树、森林、Extra Trees、AdaBoost、直方图提升、XGBoost、LightGBM、CatBoost。
- **邻域与基函数**：K 近邻、ELM、RBF 网络。
- **端到端网络**：MLP、残差 MLP、Deep & Cross、门控 MLP、字段 Transformer。

共二十一个表格模型条目。分类采用相应分类器；网络为明确的小型本地实现，不声称复现同名论文的完整训练方案。

超参数搜索与消融规则

- 每项可训练模型分别做网格和 TPE，使用同一有限参数域和评价次数。
- 大部分域为八点；无惩罚线性模型只比较两种截距配置。
- 端到端网络固定四十轮，搜索宽度、学习率和权重衰减；验证曲线只记录，不选轮数。
- 所有特征消融重新拟合预处理并网格调参；五项表格网络另做结构控制。

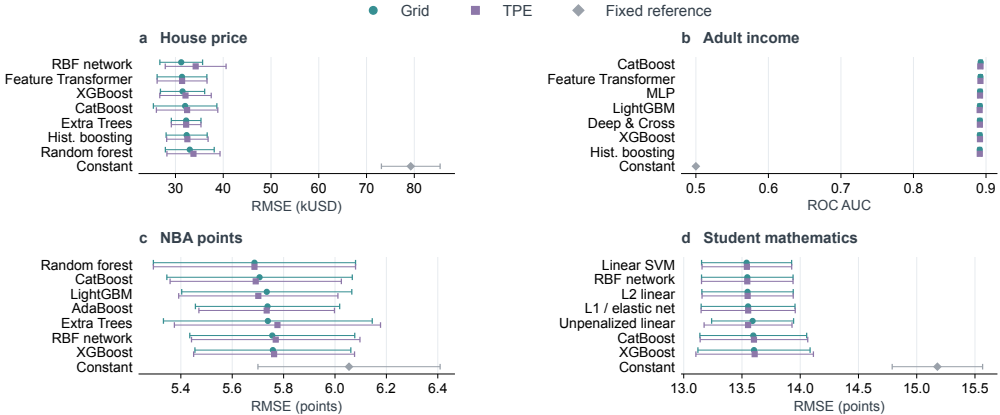
常数与沿用上季得分是固定参照。TPE 允许重复配置，重复评分复用并保留轨迹；外层成绩不用于反复修改候选域。

四任务模型比较结果

任务	网格流程中较优条目	三折均值 ± 标准差
房价	RBF 网络	31.20 ± 4.47
收入分类	CatBoost	0.8926 ± 0.0023
NBA 得分	随机森林	5.687 ± 0.393
学生数学	线性 SVM	13.540 ± 0.387

房价以千美元 RMSE、收入以 AUC、其余以分数 RMSE 评价。标准差描述三折波动；这些是本轮候选域和预算下的排序。

树模型、线性方法与网络



图中取每任务网格前七项及常数参照，论文保留全部二十一项。两种搜索同时显示，误差线为三折标准差，未按外层结果替模型选择搜索方法。

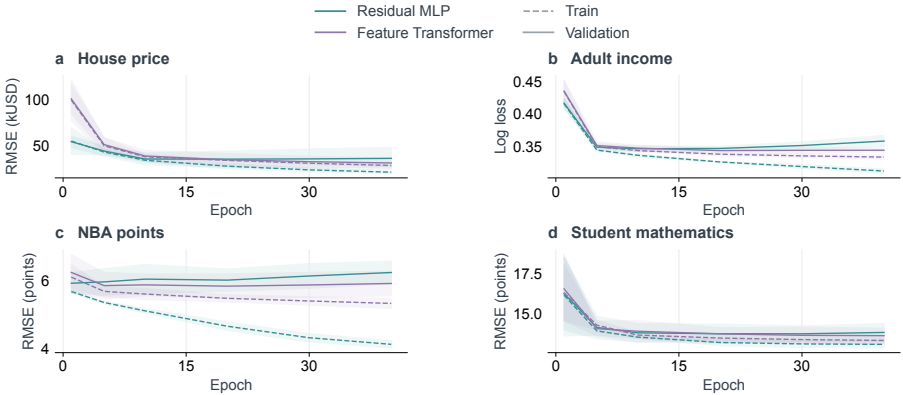
网格与 TPE 的外层差异

任务	TPE 改善	相同	退化
房价	5	2	13
收入分类	5	3	12
NBA 得分	7	2	11
学生数学	5	3	12
NBA 下一赛季	5	1	7

内层最优组合的优势未必保持到外层；搜索方法按外层差值评价。

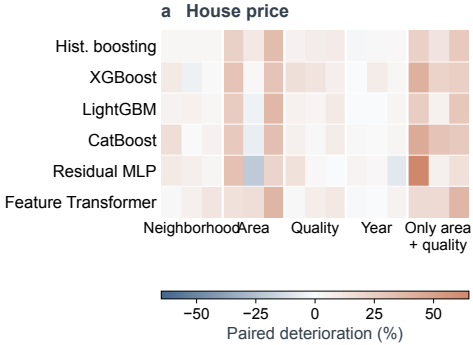
改善指 AUC 增加或 RMSE 降低。相同使用数值容差 10^{-9}。TPE 重复次数、实际访问组合及每折差值完整保存。

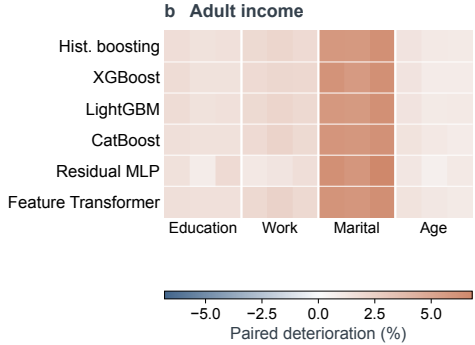
神经网络的拟合诊断



曲线固定展示残差 MLP 与字段 Transformer，不按外层成绩挑选。虚线为训练、实线为验证，阴影为三折标准差；固定训练四十轮，不以外层曲线选择轮数。

特征组消融

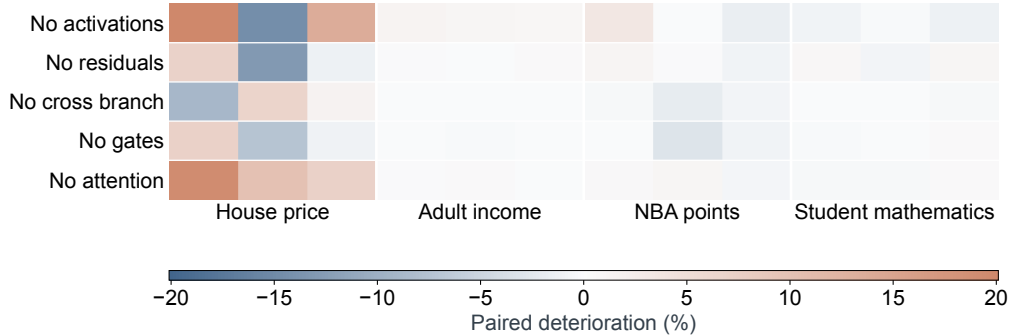




固定提升树删去面积组后，RMSE 平均增加 7,000.29 美元；SHAP 最高则为整体质量。重新训练检验其余字段能否替代。

展示房价、收入的六项预定对照，完整四任务与全部模型见论文。每格三个色条依次为三个外层折；正值表示退化。Only area + quality 仅保留居住面积与整体质量。

网络部件的结构控制



关闭一个部件后，也重新进行内层网格搜索。

依次关闭激活、残差连接、交叉输出、门控和自注意力。每个任务的三个色条为配对外层折，正值表示损失；不同部件的比较限于本地实现。

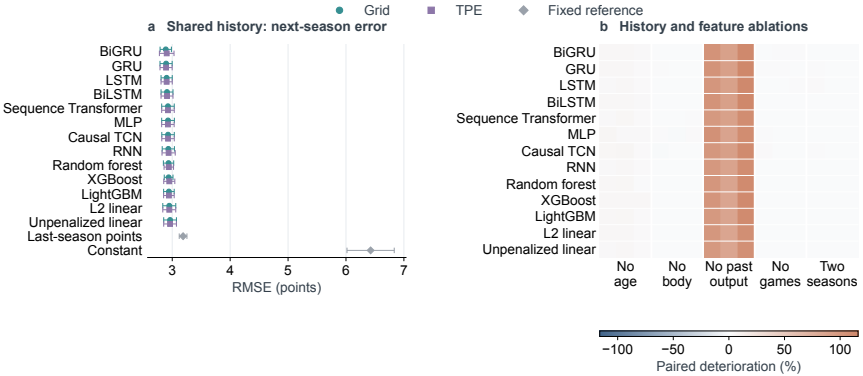
NBA：从历史赛季预测下一赛季

$$\hat{y}_t = f\big(X_{t-3}, X_{t-2}, X_{t-1}\big)$$

- 每季输入年龄、身高、体重、得分、篮板、助攻和出场数。
- RNN、GRU、BiGRU、LSTM、BiLSTM、因果 TCN 和序列 Transformer 保留时间轴。
- 线性、森林、提升树与 MLP 接收同样的历史信息；沿用上季得分作固定参照。

按目标赛季向前验证。双向网络只编码预测时已知的历史；姓名等组合键并非已核实的球员编号。

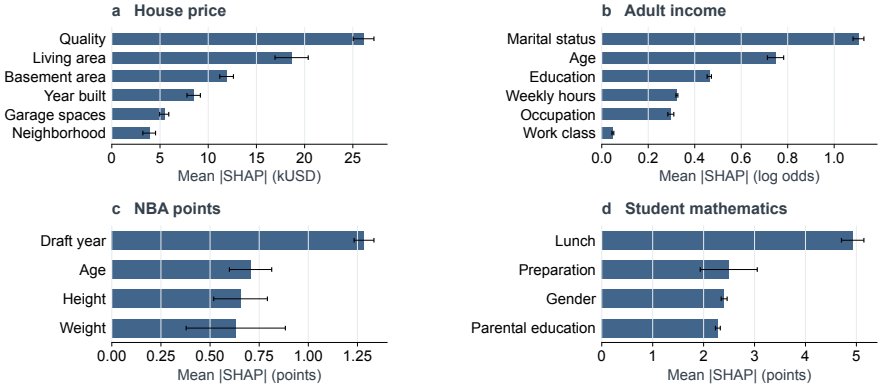
NBA 历史窗口的比较与消融



网格流程中较小平均 RMSE 来自 BiGRU（2.888 分）。

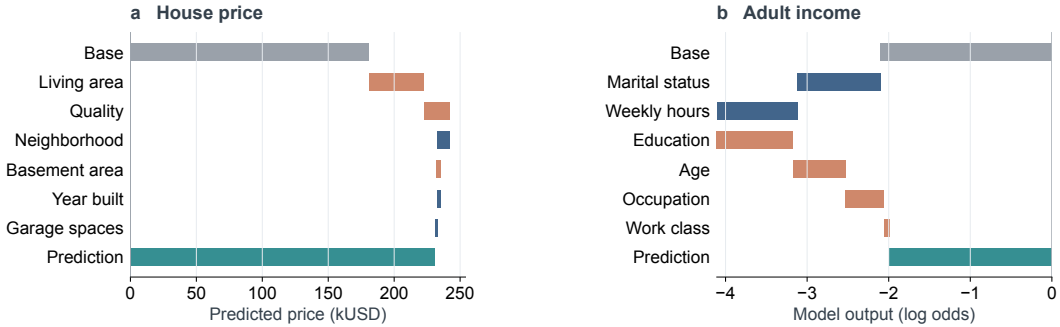
十五项条目共用 6,228 个目标窗口，误差线为三折标准差。十三项拟合模型分别删除字段组或改为两季输入，目标记录保持一致；不能与原四字段 NBA 误差直接比较。

固定提升树的 SHAP 全局解释



解释模型在实验前固定为网格提升树。覆盖四任务全部外层验证记录；贡献先合并到原字段再取绝对值，误差线为三折标准差。SHAP 与重新训练的消融回答不同问题。

单条预测的贡献分解



房价、收入各选一条绝对误差居中的记录。基准加字段贡献重建原始输出，分类在对数几率尺度分解；行号、实际值、预测值及贡献加和核对随图保存。

表格问答的计算与检索检查

社区均价计算

CollgCr 社区中，成交价有记录的房屋共 150 条。

$$\bar{y} = \frac{29{,}694{,}866}{150}$$

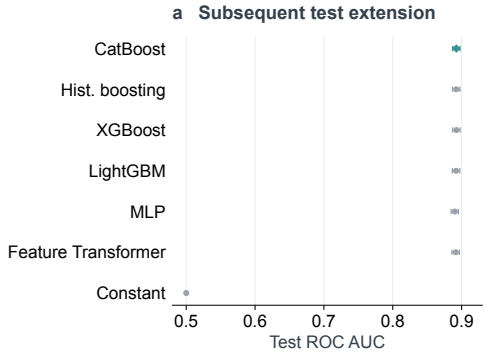
均价为 197,965.77 美元。

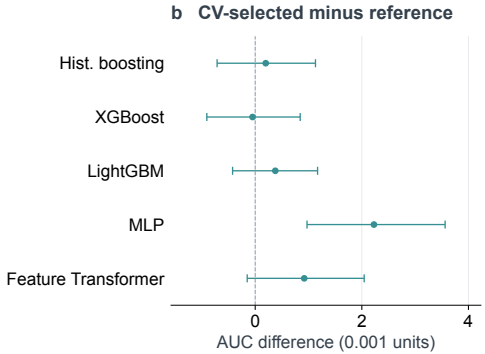
字段检索检查

- 四份表各四题，共十六题。
- 十五题排第一，一题排第二；MRR 为 0.96875。
- 十五题直接含英文字段名。

均价使用人工固定方案；检索结果不能替代真实 DeepSeek API 的方案生成质量评价。

Adult 后续扩展测试





按 CV 预选的 CatBoost 测试 AUC 为 0.8924，95% 区间 [0.8871, 0.8977]。

原测试已用于前期十三流程，本轮按后续扩展报告，不称新的盲测。全部二十一项见论文；此处展示预选模型、固定参照和常数。16,255 条测试，排除跨文件重复 26 条；测试后未回调参数。

开源与复现

github.com/Karcen/TableLab_DeepSeek

1. 启动一次网页准备环境，再运行 `Run-Expanded.command`。
2. 对照 `artifacts/expanded` 的协议、分折、参数、模型与逐条预测。
3. 运行核对入口，复算外层指标、SHAP 加和，并记录提交与依赖版本。

本轮 1,791 项流程、外层折与消融组合；6,129 项外层指标复算通过。批量实验不调用 API；绘图用指定 Nature Skills，文档用 XeLaTeX。

优点与不足

优点（Pros）

- 多类模型共用外层样本与输入。
- 调参与预处理限定在训练折内。
- 所有可训练模型重新调参做消融。
- 保存参数、模型和逐条预测供复算。

不足（Cons）

- Adult 为后续扩展测试，其余任务缺新独立样本。
- 网络仅用小型结构、四十轮和有限搜索域。
- NBA 缺少已核实的球员编号。
- 检索仅十六题；真实 API 方案质量未评价。
- SHAP 与消融不直接估计因果效应。