天津大学

TableLab：基于本地字段检索的中文表格问答与预测

机器学习课程报告

学　院：马寅初经济学院

专　业：应用经济学

姓　名：郑嘉诚

学　号：2026209004

2026 年 11 月 1 日

TableLab：基于本地字段检索的中文表格问答与预测

郑嘉诚

马寅初经济学院　应用经济学　2026209004

摘要

TableLab 在本地检索字段说明，通过 DeepSeek API 生成分析方案，再由本机程序完成统计与模型训练。字段检索检查限于 16 道固定题，其中 15 道含英文字段名；DeepSeek API 的方案生成质量尚未评价。本文用房价、收入分类、NBA 得分和学生成绩四个任务比较九种预设方法，并对森林与梯度提升分别进行网格和 TPE 搜索。外层三折评价训练流程，内层三折选择参数；训练与验证曲线检查拟合差距，SHAP 和重新调参的特征组消融检查模型依赖。房价的较小平均 RMSE 为 32,338.23 美元，来自提升树＋网格；收入分类中，提升树＋网格的 AUC 为 0.8913。NBA 得分由随机森林取得较小平均误差（5.698 分），学生成绩则是 Ridge（13.545 分）。各任务的较优方法与搜索收益不同，解释和消融结果也需结合字段之间的替代关系判断。

关键词

表格问答；嵌套交叉验证；超参数搜索；SHAP；消融实验

目录

I 研究问题 3
II 结果 3
III 意义 12
IV 方法 14
附录 A: 数学推导与计算示例 19
附录 B: 统计计算与分析参数 30
附录 C: 补充数据与实验图 32
附录 D: 实现、数据与运行记录 34
参考文献 39

I. 研究问题

房价表有 81 列。用户问“CollgCr 社区的平均成交价是多少”，实际只需要两列：社区和成交价。先按社区筛选，再给剩下的成交价求平均。如果把所有社区都算进去，程序仍能给出一个均价，但它回答了另一个问题。预测还多一项选择。要估算一套房屋的价格，必须先说明估价时知道哪些房屋属性。

表格问答有几种做法。Herzig et al. [1] 提出的 TaPas 从表中选择单元格，再对所选数值求和、计数或取平均。另一类方法在生成答案前先查资料。Lewis et al. [2] 把这一做法称为检索增强生成（RAG）。本文把检索用于字段说明。检索器查找“成交价”对应哪一列，计算程序读取该列中符合条件的全部记录。这种分工也适合预测任务：检索器查找用户指定的变量，统计程序用这些变量重新拟合模型。

本文分别检查字段检索和模型预测。检索实验记录所需字段在返回结果中的排名。预测实验在同一批验证记录上比较不同输入变量和算法的误差。选列和计算各有可能出错：即使均值算对了，选错列也会答非所问。因此两项实验分别报告。

本文在原固定参数复核之外，比较多类模型及两种超参数搜索，检查训练误差与验证误差的分离，并用字段贡献和重新训练的消融分析预测依据。

II. 结果

A. 多模型与嵌套验证

本轮比较九种预设方法，并为随机森林、梯度提升各增加网格和 TPE 搜索，共形成每个任务十三条比较流程。房价的较小平均 RMSE 为 32,338.23 美元，来自提升树＋网格；收入分类中，提升树＋网格的 AUC 为 0.8913。NBA 得分由随机森林取得较小平均误差（5.698 分），学生成绩则是 Ridge（13.545 分）。这些是三折验证中的描述性排序，各折结果见图 1。

B. 网格与 *TPE* 贝叶斯搜索的实际收益

房价中，提升树的网格与 TPE 搜索都使平均 RMSE 比预设参数低 966.57 美元；NBA 的降幅为 0.014 分。学生任务两条流程分别降低 0.115 和 0.082 分，收入分类的平均 AUC 增量约为 0.0001。

森林在收入分类与 NBA 任务中的调参结果反而略差。这些参数由内层选择，外层退化说明内层最优组合的收益未必能在另一批记录上保持。

两种搜索使用相同的十二点离散域；网格遍历全部组合，TPE 允许重复访问。每个任务中提升树的 TPE 平均访问约七至八种不同组合，其最终外层表现有时与网格相同。比较范围是本次候选域和预算；搜索轨迹、重复次数及耗时一并保留。

C. 训练误差与验证误差

完整决策树在收入分类中的平均训练对数损失为 0.068，外层验证为 6.546；房价训练 RMSE 为 1,073.25 美元，验证为 44,611.87 美元。模型在训练记录上的低误差没有保持到验证记录，过拟合迹象较为清楚。复杂度曲线再观察树深增加后，训练和验证误差如何分离。

表 I 三折外层验证的均值与折间标准差

方法	房价 RMSE	收入 AUC	NBA RMSE	成绩 RMSE
常数基线	79.26 ± 6.14	0.5000 ± 0.0000	6.055 ± 0.355	15.178 ± 0.388
逻辑回归 / OLS	36.33 ± 6.61	0.8826 ± 0.0038	6.003 ± 0.354	13.552 ± 0.377
强 L2 / Ridge	36.72 ± 7.11	0.8823 ± 0.0037	5.977 ± 0.350	13.545 ± 0.395
L1 / Elastic Net	58.51 ± 5.86	0.8819 ± 0.0036	6.055 ± 0.355	15.178 ± 0.388
单棵决策树	44.61 ± 8.82	0.7282 ± 0.0046	7.045 ± 0.329	13.890 ± 0.546
随机森林	33.94 ± 4.44	0.8900 ± 0.0024	5.698 ± 0.374	13.692 ± 0.486
Extra Trees	32.98 ± 3.80	0.8797 ± 0.0035	5.756 ± 0.402	13.806 ± 0.473
直方图梯度提升	33.30 ± 4.46	0.8912 ± 0.0028	5.767 ± 0.329	13.724 ± 0.506
K 近邻	34.07 ± 4.89	0.8757 ± 0.0029	5.987 ± 0.400	13.859 ± 0.527
森林＋网格	32.70 ± 4.51	0.8880 ± 0.0032	5.740 ± 0.396	13.619 ± 0.441
森林＋ TPE	32.91 ± 4.50	0.8876 ± 0.0025	5.738 ± 0.392	13.629 ± 0.435
提升树＋网格	32.34 ± 4.30	0.8913 ± 0.0025	5.754 ± 0.307	13.609 ± 0.488
提升树＋ TPE	32.34 ± 4.30	0.8913 ± 0.0025	5.754 ± 0.307	13.642 ± 0.469

房价单位为千美元，NBA 与成绩单位为分；AUC 越高越好，其余指标越低越好。误差项为三折间样本标准差。各折训练集有重合，标准差用于描述波动。NBA 和学生的 Elastic Net 在各自三折中斜率均为零，因此结果与训练均值基线一致；惩罚参数见方法部分。

浅树也会遗漏预测信息。房价的树深从 1 增至 4 后，平均验证 RMSE 从 58,732.35 降至 48,962.46 美元；学生任务从 14.211 降至 13.920 分，训练误差也同时下降。收入分类的验证对数损失由 0.447 降至 0.377，这些变化与浅树拟合不足的解释一致。NBA 从 5.815 降至 5.801 分，变化相对折间波动很小，需要结合其他模型判断。

学习曲线固定各外层训练折选出的提升树参数，再增加训练数据量。训练和验证误差都高时，还需检查输入信息是否充分；仅凭误差水平，难以将特征不足与模型欠拟合分开。

D. SHAP 解释与特征组消融

SHAP 与消融统一采用事先指定的网格调参提升树，避免为了得到某种解释而挑选模型。

房价的平均绝对 SHAP 以整体质量最高，但删去面积组后的退化最大，RMSE 平均增加 7,000.18 美元。SHAP 分配的是既定模型中的预测贡献；重新训练的消融允许其余字段替代被删信息，两种排序因而可以不同。

其余任务中，收入分类以婚姻状况、NBA 以选秀年份、学生成绩以午餐类别的平均绝对贡献较大。删去对应字段后，收入 AUC 平均下降 0.0535，NBA 与学生的 RMSE 分别增加 0.263 和 1.043 分。

E. 原单次划分的计算复核

16 道固定题在四份数据中各占 4 道。每题指定一条应当返回的字段或方法说明，再记录它的排名。15 道题的目标说明排在第一位。余下一题问 “`player_name` 是唯一球员身份吗?”。检索器先返回身高说明，再返回姓名说明。因此前六位命中 16 次，平均倒数排名为 $(15 + 1/2)/16 = 0.96875$。

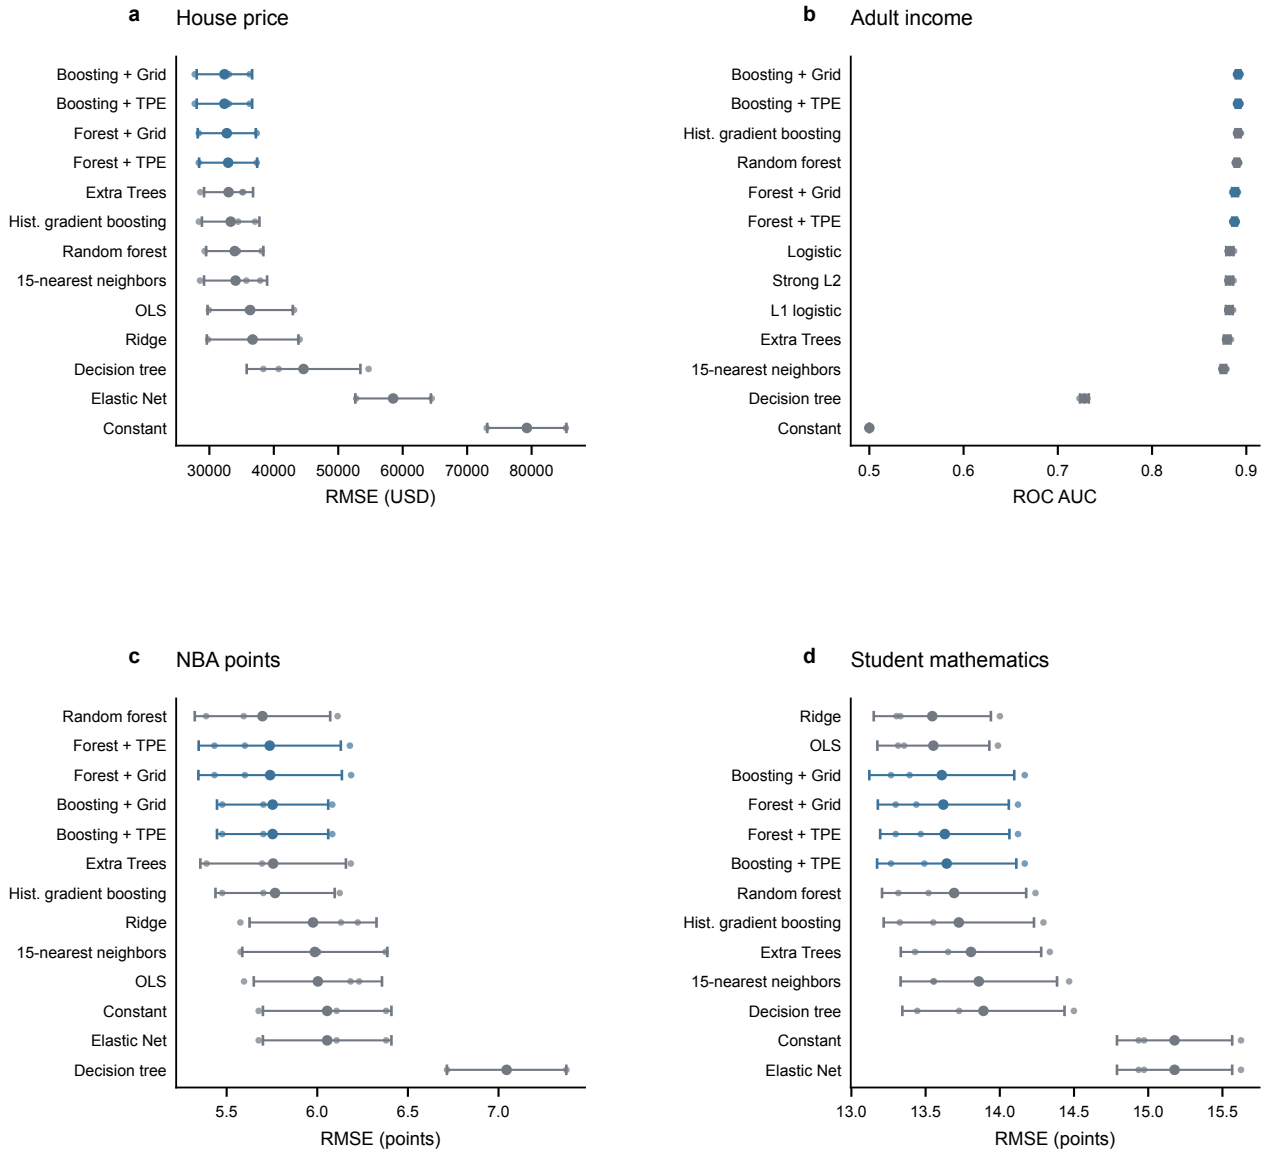


图 1 九种预设方法及四条调参流程的外层表现。小点为各折，较大点与误差线为三折均值与标准差。按各任务自身指标排序，不能跨任务比较数值大小。

题库中 15 道题直接写出了目标英文字段名。这组排名反映了这些固定问法下的字段查找结果。自由中文提问与 API 方案质量的后续评价办法见附录 D-E。

1) 房价预测: 房价实验比较两组输入变量。一组使用面积和整体质量，另一组再加入四个变量。按行号核对后，两组使用相同的 1,168 条训练记录和 292 条验证记录。

加入四个变量后，两种模型的误差都下降。即使用线性回归，六个变量算出的 RMSE 也比两变量随机森林低约 2,744 美元。这说明输入变量会影响算法之间的比较。表 II 记录的是同时加入四个变量后的变化，各变量的单独作用需要另做比较。

六变量线性回归的 MAE 为 22,339.33 美元，随机森林为 20,019.09 美元。用一条验证记录可以

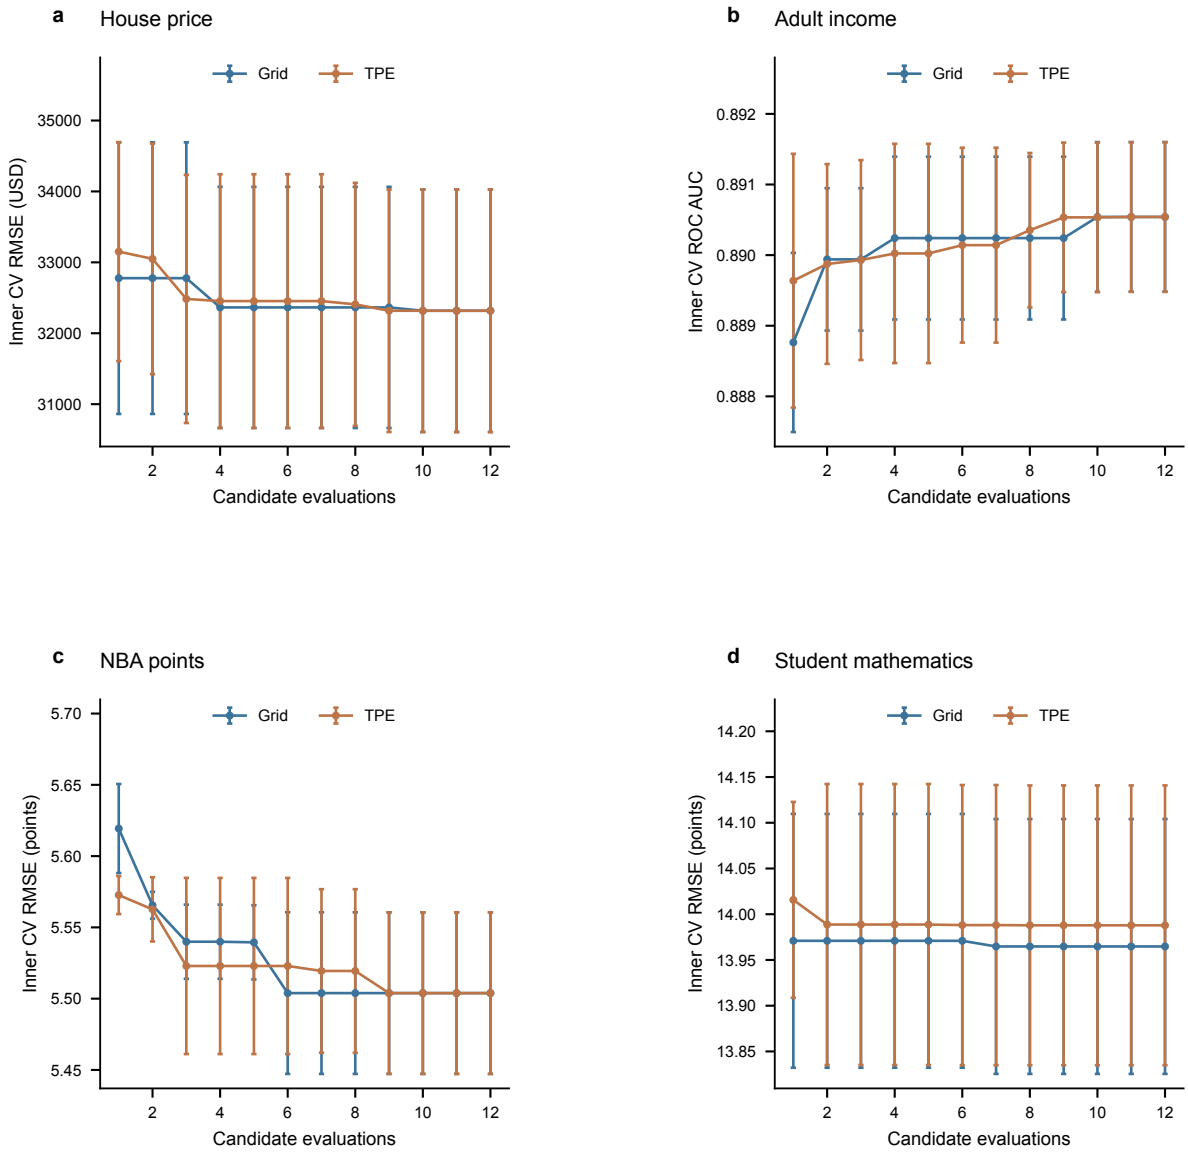


图 2 提升树内层搜索轨迹。每条线为截至相应候选次数的最优内层分数，误差线为三个外层训练子集上该分数的标准差。网格横轴表示预设枚举顺序，TPE 按已有结果选择下一候选。内层曲线用于观察搜索过程，最终表现由外层记录评价。

表 II 相同的 292 套房屋，不同的估价方法

输入变量	线性回归 RMSE（美元）	随机森林 RMSE（美元）
面积、整体质量	44,159.60	39,205.81
再加建成年份、地下室面积、车位数、社区	36,461.68	33,611.50

注：给每套房屋都预测训练均价时，RMSE 为 87,619.03 美元。两字段结果来自演示计算，六字段结果来自固定基准实验。两组均有逐条验证预测。

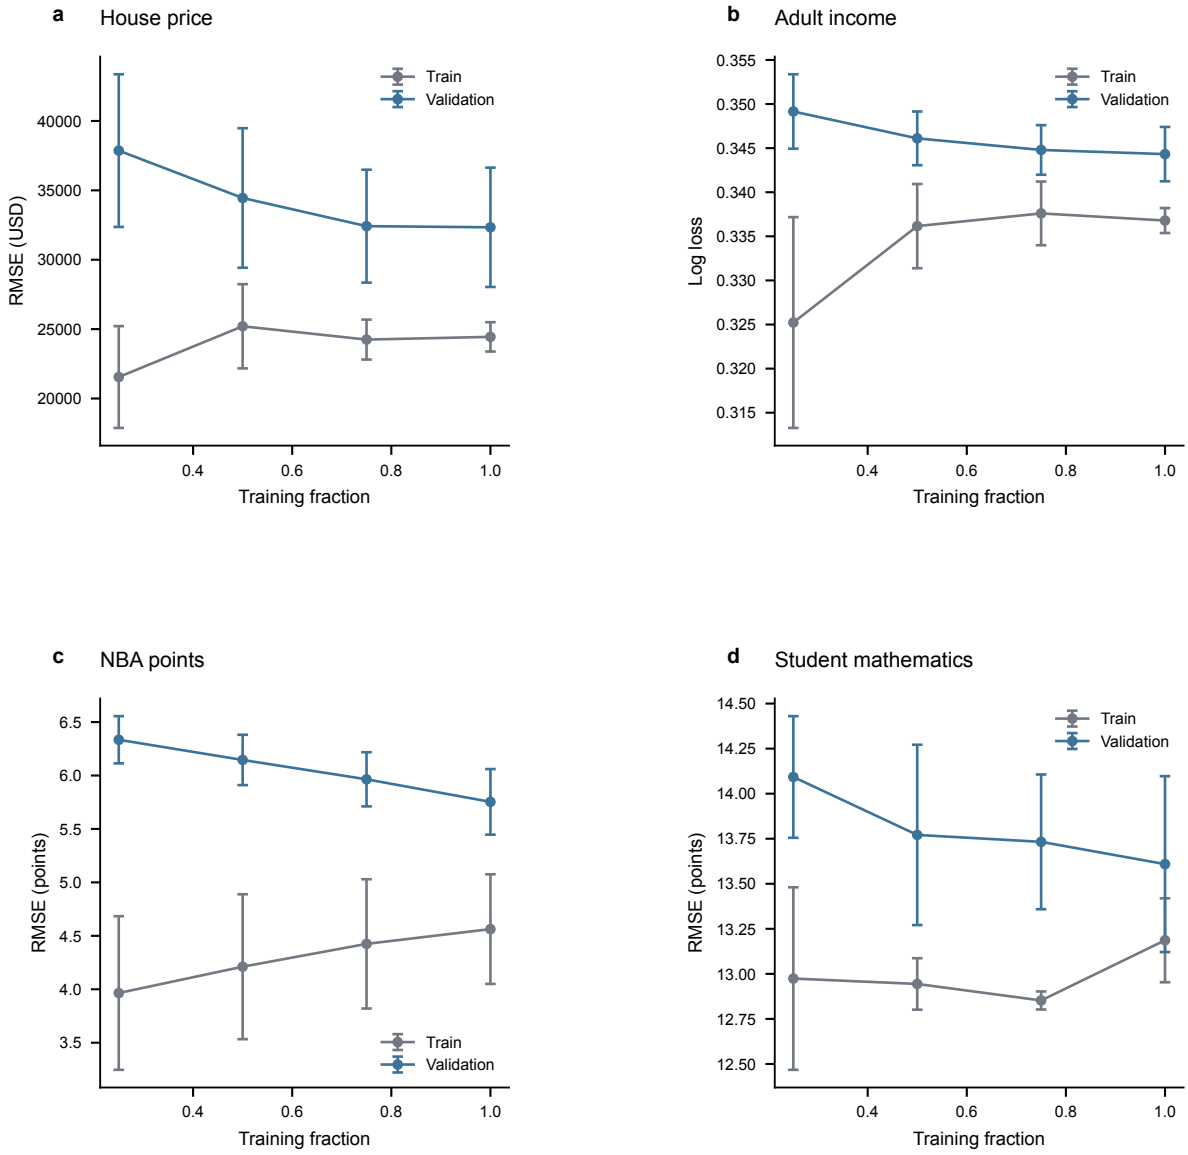


图 3 学习曲线。横轴为外层训练集使用比例，NBA 按最早的完整赛季逐步增加，Adult 按记录指纹组增加；其余任务使用固定顺序的嵌套子样本。各子样本重新拟合预处理。训练与验证点均为三折均值，误差线为折间标准差。分类使用对数损失，回归使用 RMSE。

直接看出误差的含义。编号 893 的房屋成交价为 154,500 美元，线性回归估价为 141,984.82 美元，低估 12,515.18 美元。计算 MAE 时，这套房屋贡献 12,515.18 美元的绝对误差。计算 RMSE 时，这项误差先取平方。

另一次实验把 2010 年成交的 175 套房屋整年留出，用 2006 至 2009 年的 1,285 套拟合模型。六字段线性回归和森林的 RMSE 分别为 35,008.88 和 30,310.72 美元。森林在两种划分中都取得较小误差。两种划分使用不同的验证房屋，因此分别比较各自的模型误差。

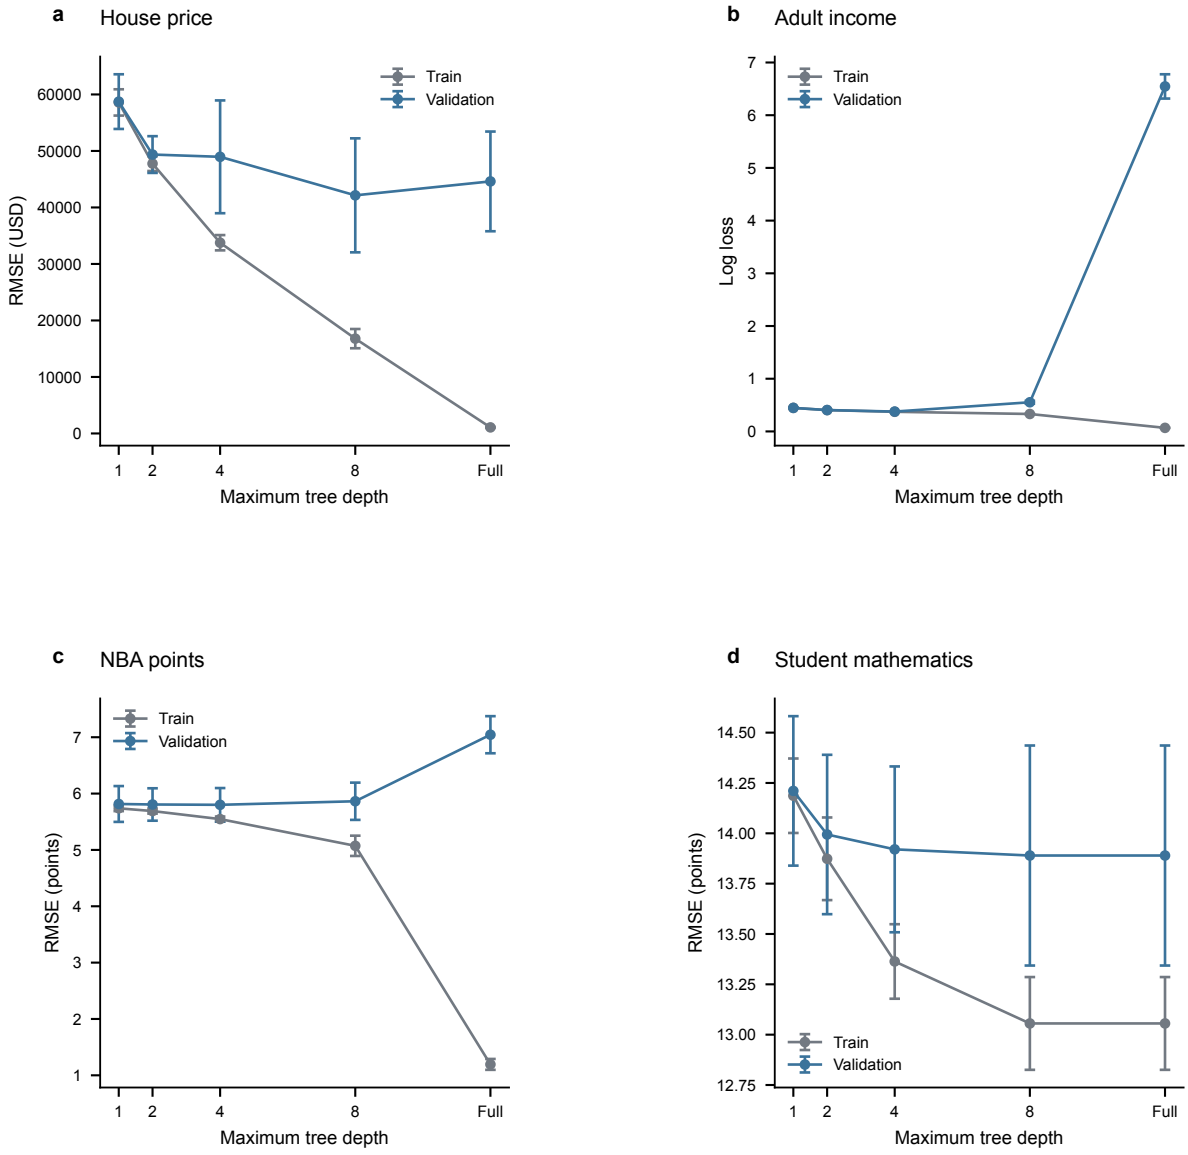


图 4 决策树复杂度曲线。Full 表示不限制树深。训练与验证使用同一误差定义；相邻折有重合训练样本，误差线描述折间差异。

2) 收入分类： 验证集的 6,512 条记录中有 1,568 个正例。图 10 比较两种模型在不同阈值下的分类结果。纵轴是在实际高收入者中判对的比例。横轴是在其余人中误判为高收入的比例。曲线下面积（AUC）可以理解为，从验证集各取一条正例和负例时，模型给正例更高分的比例；并列分数计作一半。随机森林的 AUC 为 0.8905，逻辑回归为 0.8839。

固定阈值后，可以直接数出多少人被分错。表 III 给出阈值为 0.5 时的结果。与逻辑回归相比，森林少了 86 条误报，同时多了 58 条漏报。设 TP 为正确识别的正例数，FP 为误报数，FN 为漏报数。把森林的计数代入 $F_1 = 2TP/(2TP+FP+FN)$，得到 $2\times 791/(2\times 791+315+777) = 0.5916$。森林在排序上占优，在这个阈值下的 F_1 却较低。

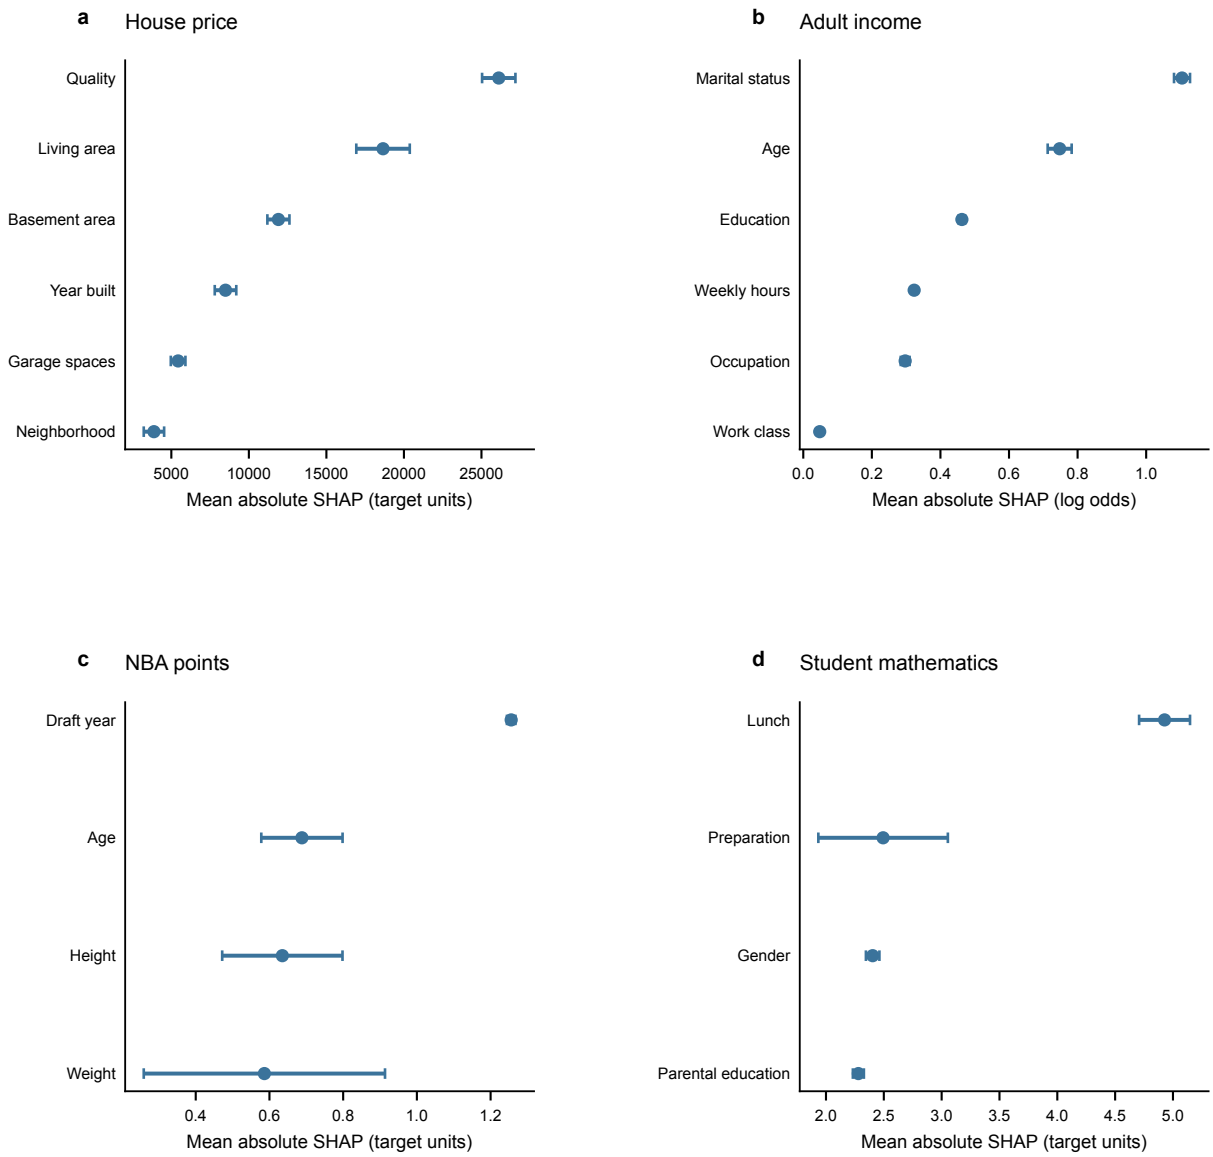


图 5 原始字段层面的平均绝对 SHAP。先对每条记录中属于同一原始字段的编码贡献求和，再取绝对值；点与误差线表示各折平均绝对贡献的均值和标准差。分类单位为对数几率，回归单位与目标一致。全部外层验证记录参与计算。

表 III 固定阈值下的两类错误与概率误差

模型	识别正例	误报	漏报	F_1	Brier 分数	对数损失
逻辑回归	849	401	719	0.6026	0.1150	0.3559
随机森林	791	315	777	0.5916	0.1125	0.3484

注：前四项使用 0.5 的阈值。后两项直接用概率计算，越小越好。Brier 分数是 $(p_i - y_i)^2$ 的样本均值。对所有人都预测训练样本的正类比例时，该分数为 0.1828。

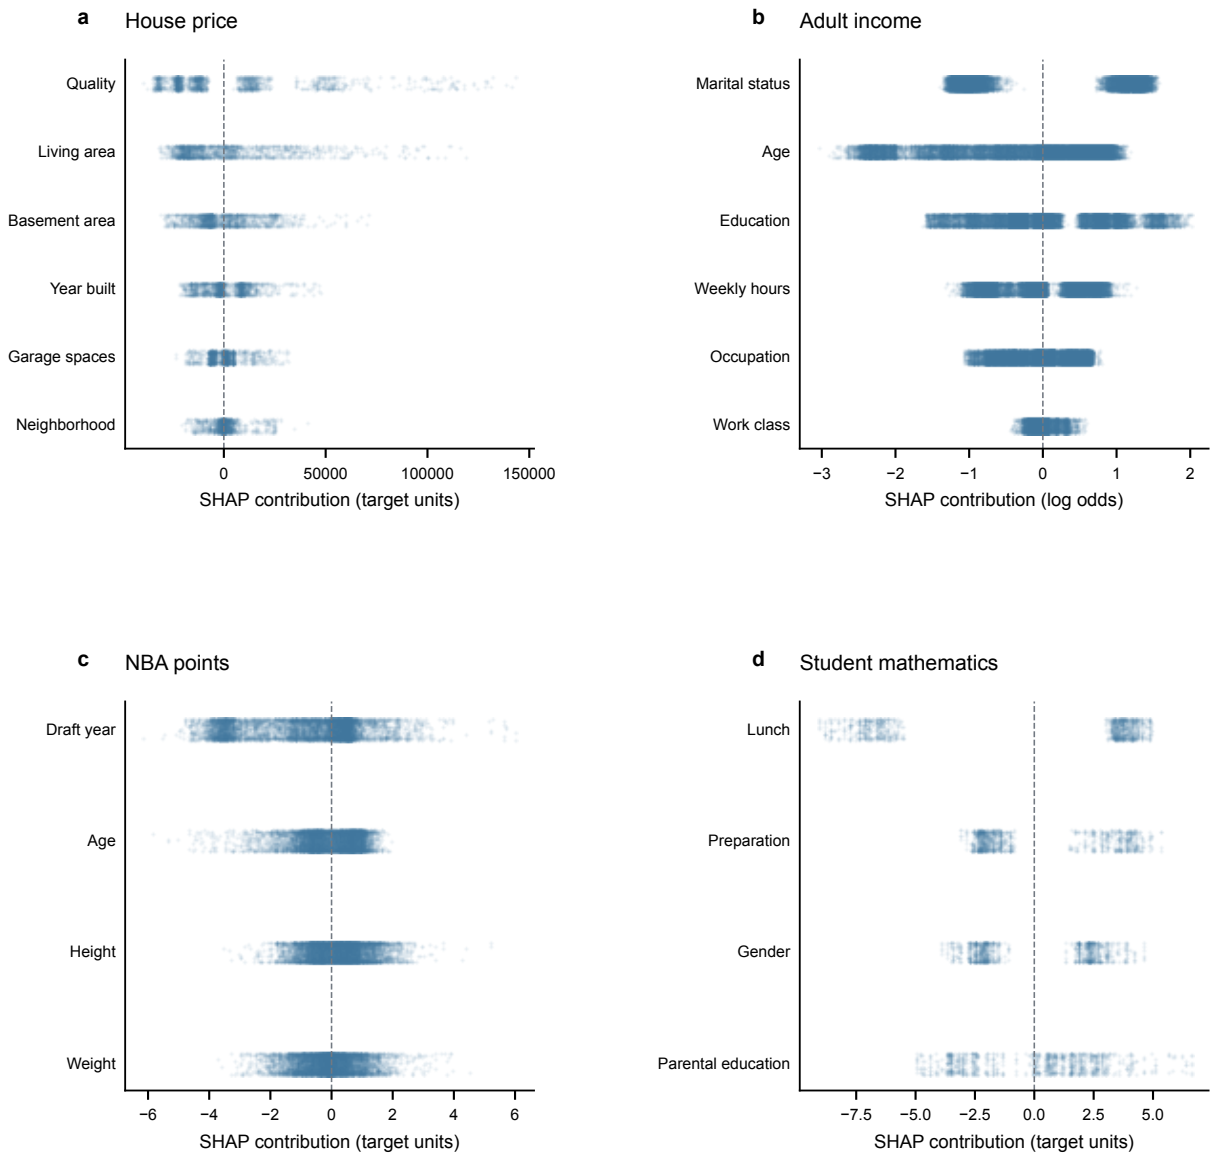


图 6 SHAP 贡献分布。每点对应一条外层验证记录在相应原始字段上的贡献；纵向抖动只用于显示重叠，横向位置保持计算值。各任务采用全部外层验证记录；类别编码贡献先按原字段相加。

3) 球员得分与学生成绩： 分数预测也可以和训练均值比较。NBA 的四个输入中没有上场时间或同期得分数据。按后六个赛季验证时，随机森林的 RMSE 为 6.112 分，常数预测为 6.380 分，差约 0.27 分。按姓名划分时，森林的误差更接近常数预测。两种划分回答不同的问题：按赛季划分允许同一姓名在不同时期出现；按姓名划分将同名的全部记录留在同一侧。原表缺少稳定的球员编号，有四组姓名和赛季相同的记录，因此按姓名分组也不能精确区分每一位球员。

在 200 条学生验证记录上，线性回归的 RMSE 比森林低 0.204 分。给所有学生预测训练均分时，误差为 15.732 分。换用四个背景字段后，线性回归把误差降到 14.320 分。阅读和写作成绩如果已经公布，估计数学分数所依据的信息就变了。这些成绩没有进入考前预测。备考课程系数描述

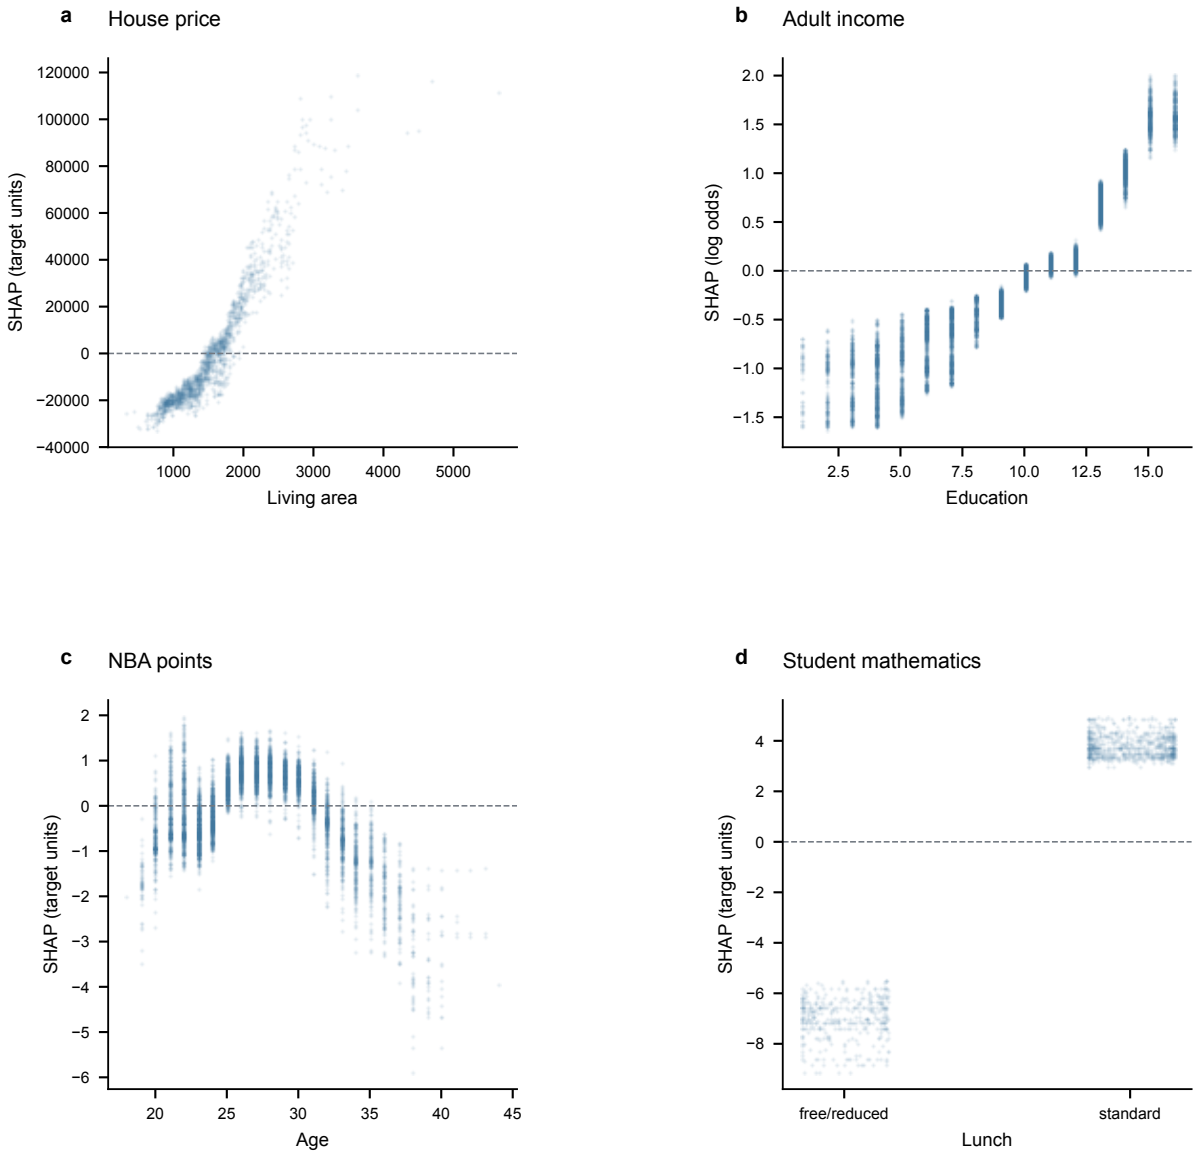


图 7 预先指定字段的取值与 SHAP 贡献。四个面板分别使用居住面积、教育编码、年龄和午餐类别；每点对应一条外层验证记录，透明度用于显示重叠。午餐类别仅沿横轴作确定性抖动。曲线或点云描述拟合模型中的关联。

表 IV 预测得分时的验证误差

		RMSE（分）			R^2	
任务与划分	验证条数	训练均值	线性回归	随机森林	线性回归	随机森林
NBA，后六季	3,283	6.380	6.231	6.112	0.0390	0.0753
NBA，按姓名分组	2,472	6.021	5.835	6.016	0.0604	0.0010
数学成绩，随机划分	200	15.732	14.320	14.524	0.1573	0.1331

注：按姓名划分时训练集有 10,372 条记录。NBA 的单位是球员场均得分，学生任务的单位是数学考试分数，各模型只在同一行内比较。

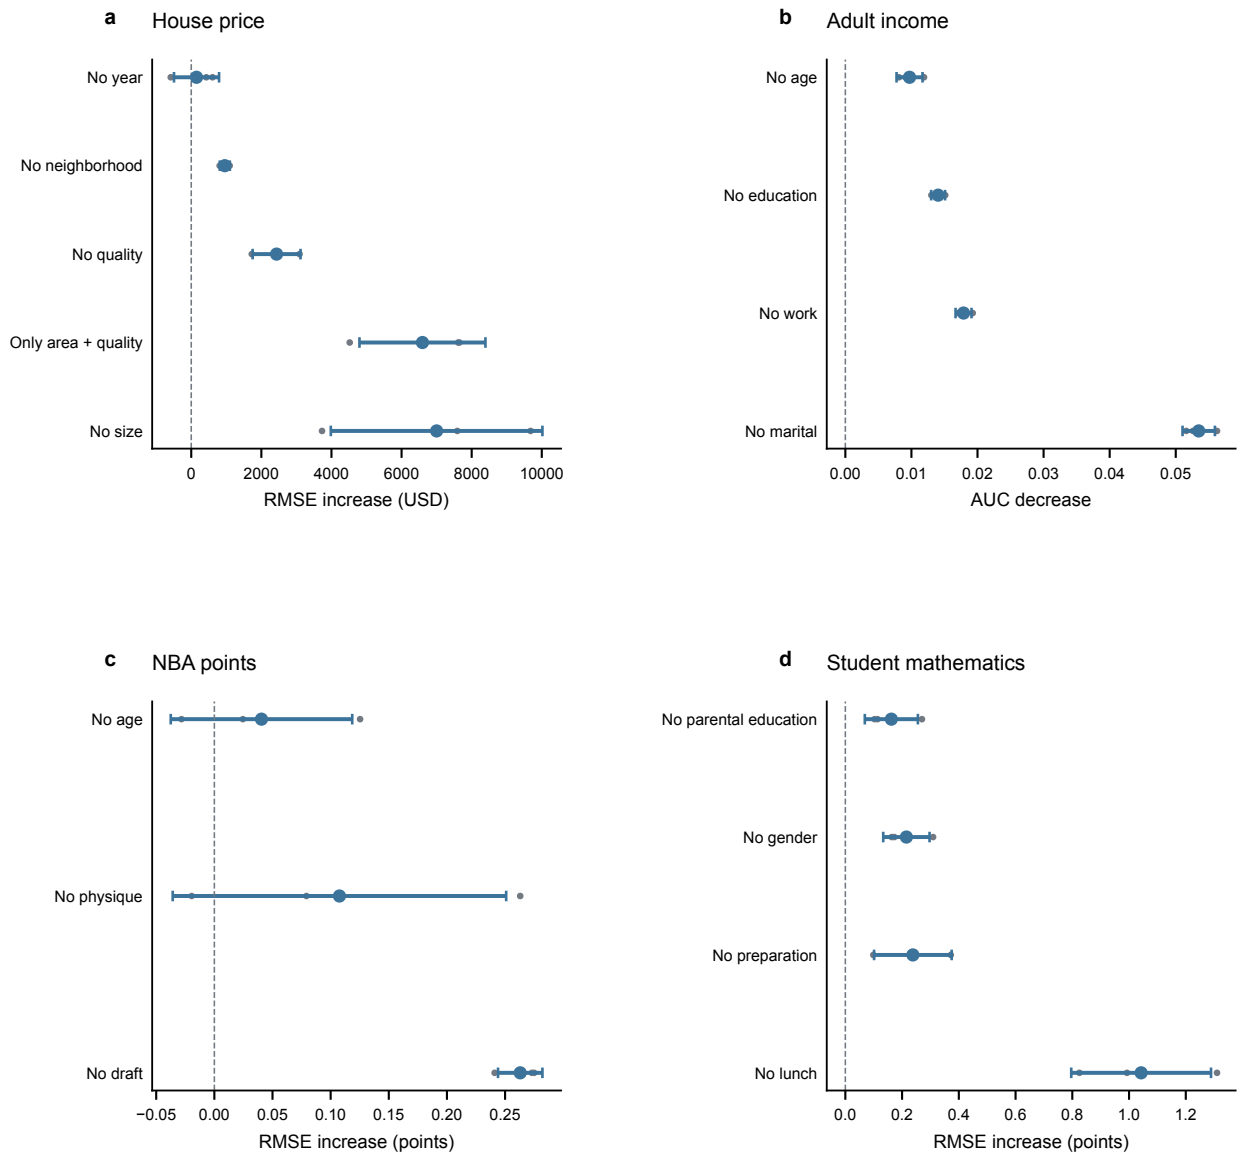


图 8 特征组消融并重新进行内层网格搜索后的性能变化。Only area + quality 表示仅保留地上居住面积与整体质量，其余 No 标签表示删去对应字段或组。正值表示相对全部字段的性能损失，负值表示改善；同一折的两种配置使用完全相同的训练与验证记录。点与误差线为三折配对变化的均值和标准差。

样本中的关联。估计课程效果还需要了解学生参加课程的方式。

III. 意义

四个任务使用不同的观测单位与预测信息。增加模型与搜索参数后，仍需按任务判断收益。完整树的训练与验证差距说明，仅降低训练误差不足以说明模型有效。SHAP 和重新训练的消融提供了两种检查字段依赖的办法；相关字段之间可以互相替代，因此解释结果应结合输入信息阅读。

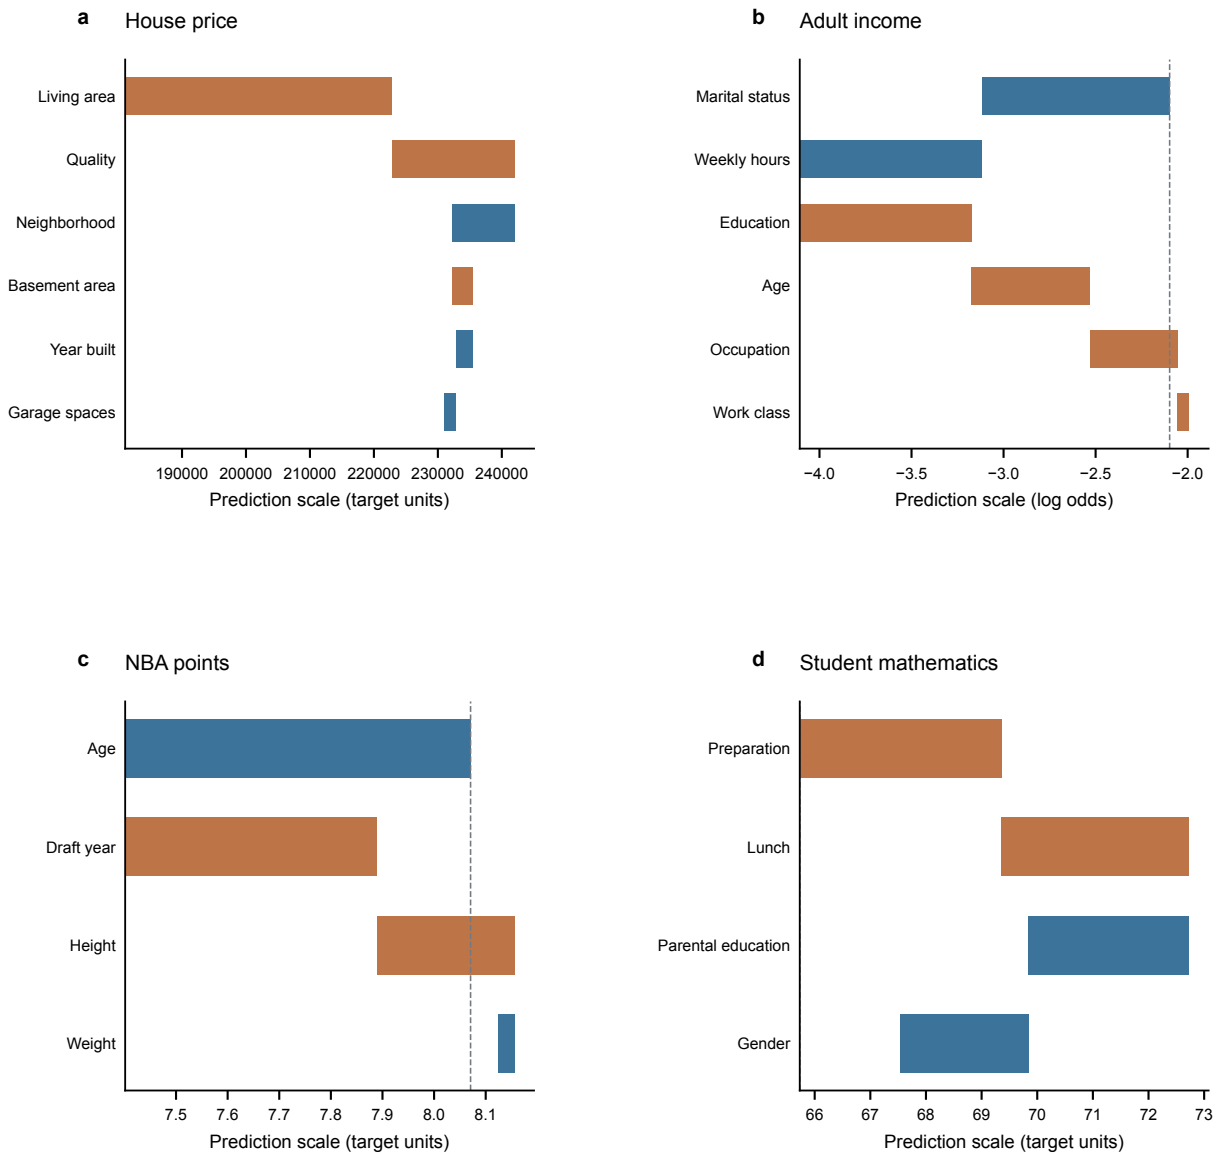


图 9 代表性单条预测的字段贡献。每个任务按全部外层验证记录的绝对预测误差排序，取中间记录；橙色条提高预测，蓝色条降低预测，虚线表示基准输出。分类在对数几率尺度分解，回归在目标单位分解；具体行号、真实值、预测值与加和核对保存在计算记录中。

嵌套验证允许比较包括调参在内的训练流程。三折结果保留各折样本构成的差异，尤其 NBA 各验证期来自不同赛季；折间标准差用于描述这种变化。原固定划分与新增验证协议评价的是不同样本，不把两组数值直接当成调参前后的变化。十三条流程的排名由同一组外层结果确定，第一名仍可能受样本选择影响，需要新样本确认。

TableLab 将问题、字段说明与分析参数连接到实际计算。DeepSeek API 的方案生成质量尚未评价，后续办法见附录 D-E；本轮多模型实验以人工固定任务和特征检验数值训练部分。对社区或备考课程的解释限于模型利用的信息，学生数据的真实抽样过程仍需核实。

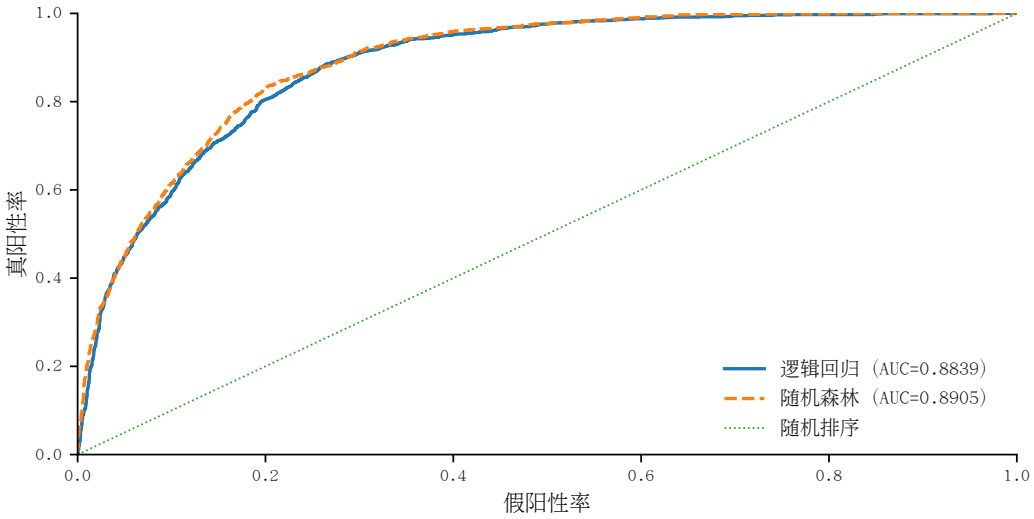


图 10 Adult 收入分类的 ROC 曲线。每个阈值对应一个点。斜虚线给出随机排序的参照。

IV. 方法

A. 数据与原单次划分复核

四份数据各自用于一个任务。房价表记录一笔交易的成交价。Adult 记录个人年收入是否超过 5 万美元。NBA 表按赛季记录球员表现，表中用姓名识别球员。学生表记录一组背景信息和三科成绩。各表单独分析。表 V 列出原单次划分复核的样本。

表 V 原单次划分复核的样本和输入变量

预测目标	原始行数	训练	验证	输入变量
成交价（美元）	1,460	1,168	292	整体质量、地上居住面积、建成年份、地下室面积、车位数、社区
高收入（是或否）	48,842	26,049	6,512	年龄、教育等级编码、周工时、用工类别、职业、婚姻状况
场均得分（分）	12,844	9,561	3,283	年龄、身高、体重、选秀年份类别
数学成绩（分）	1,000	800	200	性别、父母教育程度、午餐类别、是否完成备考课程

注：Adult 的原始行数包括独立存放的测试文件。该文件的 16,281 条记录没有参与模型拟合或本表的验证。房价和学生成绩按记录随机划分，随机种子为 42。

房价样本的列名与 Kaggle 房价竞赛的训练表相符 [3]。单独保存的 CSV 与压缩包内的文件内容相同，下载清单没有记录这份房价文件的出处。这个副本中，每一行至少有一处空白。若删除所有含空白的行，1,460 条记录将全部丢失。部分空白有可辨认的含义。例如，690 条壁炉质量为空的记录，壁炉数都为零。本文保留原记录，只处理当次模型所用的字段。

Adult 数据取自 1994 年人口普查数据库 [4]。下载清单分别登记了训练文件的 32,561 条记录和测试文件的 16,281 条记录。原训练文件中有 25 条记录的全部 14 个非目标字段与此前记录完全相同。实验先按这 14 个字段分组，再按收入类别分层划分。字段完全相同的记录留在同一组。原单次划分只用五折分组器的第一个划分。各项比例和模型都未使用人口权重。

NBA 数据覆盖 1996–97 至 2022–23 赛季 [5]。主实验用前 21 个赛季训练，用后 6 个赛季验证。预测时不使用同期投篮效率或使用率。部分属性没有采集日期，因而无法逐条确认赛季开始时的取

值。学生成绩实验按考前预测处理，排除了同期的阅读和写作成绩。该数据的发布页指向一个考试数据生成页面，未给出可核实的学生抽样过程 [6]。

B. 扩展实验的验证与搜索协议

九种预设方法包括常数基线、线性模型、较强 L2 正则模型、稀疏线性模型、完整决策树、随机森林、Extra Trees、直方图梯度提升和 K 近邻。回归的三种线性模型为 OLS、Ridge 和 Elastic Net；分类对应 L2 逻辑回归、较强 L2 逻辑回归与 L1 逻辑回归。Ridge 的 $\alpha = 10$；Elastic Net 的 $\alpha = 10$、l1_ratio $= 0.5$。普通与较强 L2 逻辑回归的 C 分别为 1 和 0.1，L1 逻辑回归取 $C = 0.1$，使用 liblinear 求解。以上均为预设参数，未参与本轮搜索。NBA 和学生的 Elastic Net 在各自三折中斜率均为零，截距等于训练均值；在此惩罚强度下，预测退化为常数。森林和 Extra Trees 使用 64 棵树、深度 12、叶节点最少 5 条；文中的“提升树”均指表 I 的直方图梯度提升，回归与分类分别使用 HistGradientBoostingRegressor 和 HistGradientBoostingClassifier；预设配置使用 100 次迭代并关闭内部随机早停。近邻数为 15。完整参数随源代码与拟合对象保存。

每个任务使用三折外层验证，内层仅在相应外层训练子集中，沿用同一分折规则再分三折搜索参数。房价和学生随机分折，种子为 42；Adult 在原训练文件内按全部非目标原始字段指纹分组并按标签分层；NBA 按完整赛季向前滚动，验证赛季晚于训练赛季。NBA 三个外层训练/验证规模分别为 3,972/2,706、6,678/2,883、9,561/3,283；最早的训练赛季不作为验证记录。其余任务每条合格记录恰好进入一次外层验证。嵌套验证将选参数与评价参数选择流程分开 [7]。

数值插补与标准化、分类缺失值处理和独热编码都在每次拟合的训练折完成。各方法使用相同字段、相同样本行号及相同内外层划分；房价保持美元原尺度，学生不输入同期其他考试成绩。原始记录与异常值的保留规则沿用数据核查。

网格搜索与基于 TPE 的贝叶斯超参数搜索，对同一个离散参数域各评估十二次。森林搜索最大深度 4、8 或不限，叶节点最少 3 或 10 条，候选特征比例 0.7 或 1；提升树搜索叶节点上限 7、15 或 31，L2 惩罚 0 或 1，学习率 0.05 或 0.1。两者均形成十二种组合。TPE（树结构 Parzen 估计）前四次为启动采样，后续根据已有参数及分数更新采样概率并选择参数，种子为 42 加外层折编号 [8]。TPE 可以重复组合，全部评估保留。分类按内层平均 AUC 选参数，回归按平均 RMSE 选参数。阈值固定为 0.5，未作阈值搜索。总计四个任务、两类模型、两种搜索、三折外层与三折内层，主搜索完成 1,728 次内层拟合；消融在此之外重复网格搜索。

C. 解释、消融与结果核对

解释模型预先固定为网格调参提升树。Tree SHAP 使用训练树路径计数作为背景分布，解释全部外层验证样本，分类输出为原始对数几率 [9]。每条记录检查基准值加全部字段贡献能否重建原始预测。类别字段先将对应编码的有符号贡献相加，再汇总绝对重要性。

房价的面积组包含地上居住面积 GrLivArea 与地下室面积 TotalBsmtSF；NBA 的身体属性组包含身高 player_height 与体重 player_weight；Adult 的工作组包含周工时 hours-per-week、用工类别 workclass 和职业 occupation。房价分别删去社区、面积组、质量和建成年份，另设仅保留地上居住面积与整体质量 OverallQual 的两字段配置；这一配置不包含地下室面积。Adult 分别删去工作组、

教育、婚姻和年龄；NBA 分别删去身体属性组、年龄和选秀年份；学生逐一删去四个背景字段。每个变体在同一外层训练记录中重新完成十二点网格搜索。消融以同折差值评价；缺少某个字段后误差变化小，也可能是其他字段提供了替代信息。SHAP 与消融用于描述预测模型，解释因果关系还需要额外的识别设计。

批量实验由独立入口运行，不调用语言模型。每折保存样本行号、内层划分、搜索轨迹、参数、拟合对象、逐条预测与 SHAP 值。另用核对脚本从逐条预测复算分类或回归指标，检查时间和分组边界、解释加和以及候选评估次数。搜索使用两个数据集进程并行，每个模型仅用一个工作线程。旧数据已参与前期分析，结果按重新定义协议的交叉验证估计报告。

D. 字段检索与统计计算

每个数据集都有一份本地字段词典。每条说明包含英文列名、中文释义和可用的取值示例。索引还收录数据范围和统计方法。房价索引共有 90 条文档。检索时，程序把问句和文档都切成相邻的 2 至 4 个字符。例如，“平均成交价”包含“平均”“成交”“交价”，也包含“成交价”。问句和说明使用同一套字符片段，因此可以直接比较。

设 c_{td} 是片段 t 在文档 d 中出现的次数，N 是索引文档数，df_t 是含有该片段的文档数。程序对出现过的片段赋予权重

$$w_{td} = (1 + \log c_{td}) \left[1 + \log \frac{N+1}{df_t + 1} \right], \qquad c_{td} > 0. \tag{1}$$

未出现的片段权重为零。一个片段在本条说明里多次出现，权重会上升。若许多说明都含有这个片段，它区分文档的作用就会减弱。用同一词表把问句 q 转成向量 w_q。对两个非零向量，程序计算余弦相似度 $s(q,d) = w_q^{\mathsf{T}} w_d / (\|w_q\|_2 \|w_d\|_2)$，最多返回分数为正的前六条说明。

对 CollgCr 的均价问题，社区列 `Neighborhood` 排在第一位，相似度为 0.176436。成交价列 `SalePrice` 排在第二位，为 0.070664。排在第四位的纱窗门廊与计算无关。计算均价时只需社区和成交价两列。

用户先选择数据集。程序通过 DeepSeek API 发送问题、字段名与类型、相关字段和方法说明，以及必要的上一轮方案，接收 JSON 分析参数。程序校验格式和列名，用户核对条件后，由本机读取原始表格计算或训练模型。生成新方案需要联网；原始 CSV 不随请求整表上传。本例采用人工指定方案，检索排名来自对原问句的实际查询。

设 S 是社区为 CollgCr 且成交价有记录的行。程序从原表读出这 150 条记录。用 y_i 表示第 i 条记录的成交价，得到

$$\bar{y}_S = \frac{\sum_{i \in S} y_i}{|S|} = \frac{29{,}694{,}866}{150} = 197{,}965.77 \text{ 美元 （保留两位小数）.} \tag{2}$$

全表均价为 180,921.20 美元。两个均价描述的样本不同，房屋面积和质量的分布也可能不同。估计地段对价格的影响，还需要考虑这些差异。

E. 预测模型与评价方法

同一个均价可以充当最简单的预测。设 $\mathcal{T}$ 是训练样本，n_T 是记录数。给所有房屋报同一个价格 c，训练样本的平方误差之和为 $L(c)=\sum_{i\in\mathcal{T}}(y_i-c)^2$。对 c 求导，得到

$$L'(c)=2\left(n_T c-\sum_{i\in\mathcal{T}} y_i\right)=0 \quad\Longrightarrow\quad \hat{c}=\bar{y}_T. \tag{3}$$

由于 $L''(c)=2n_T>0$，训练均价使误差平方和最小。后面用这个常数预测验证样本。训练均价只取训练集的成交记录，社区均价则取该社区全部有成交价的记录。

加入地上居住面积 x_i 后，直线 $a+bx_i$ 允许大房屋和小房屋有不同的预测价。令 $e_i=y_i-a-bx_i$。最小化 $\sum e_i^2$ 时，对截距和斜率求偏导，分别得到 $\sum e_i=0$ 和 $\sum x_i e_i=0$。第一式给出 $a=\bar{y}_T-b\bar{x}_T$。把它代回第二式，整理可得

$$\hat{b}=\frac{\sum_{i\in\mathcal{T}}(x_i-\bar{x}_T)(y_i-\bar{y}_T)}{\sum_{i\in\mathcal{T}}(x_i-\bar{x}_T)^2}. \tag{4}$$

例如，取房价表前三条记录。面积依次为 1,710、1,262 和 1,786 平方英尺。对应成交价为 208,500、181,500 和 223,500 美元。式 (4) 的分子为 11,748,000，分母为 160,352，斜率为每平方英尺 73.26 美元。这里的三条记录只用来说明算法。正式比较使用表 V 的训练样本。

多元模型同时使用面积、质量等变量。令 X 为处理后的训练数据矩阵，第一列全为 1，表示截距。最小化 $(y-X\beta)^{\mathsf{T}}(y-X\beta)$，得到正规方程 $X^{\mathsf{T}}X\hat{\beta}=X^{\mathsf{T}}y$。数值变量先用训练中位数填补缺失，再按训练均值和标准差缩放。类别变量单独编码。验证记录使用训练阶段得到的参数。六字段房价模型的面积系数为 24,586.18 美元，对应一个训练标准差（524.21 平方英尺）。除以 524.21，得到每平方英尺 46.90 美元。这是模型在其他五个变量不变时给出的价格差。

Adult 的收入标签只有两个取值。年收入超过 5 万美元时 $y_i=1$，其余记录 $y_i=0$。记 p_i 为模型给出的高收入概率，z_i 为第 i 条记录处理后的特征。逻辑回归令对数几率等于线性预测值 $\eta_i=\beta_0+z_i^{\mathsf{T}}\beta$。将对数几率还原为概率，得到

$$\log\frac{p_i}{1-p_i}=\eta_i \quad\Longrightarrow\quad p_i=e^{\eta_i}(1-p_i) \quad\Longrightarrow\quad p_i=\frac{1}{1+e^{-\eta_i}}. \tag{5}$$

每条记录的实际标签给出一项似然 $p_i^{y_i}(1-p_i)^{1-y_i}$。把训练样本各项相乘，取负对数，再对斜率加入平方惩罚。逻辑回归最小化以下损失 [10]：

$$-\sum_{i\in\mathcal{T}}\big[y_i\log p_i+(1-y_i)\log(1-p_i)\big]+\frac{1}{2C}\sum_{j=1}^{p}\beta_j^2, \qquad C=1. \tag{6}$$

求和中的 p 表示编码后的特征数。惩罚项不包含截距。模型按 0.5 的阈值给出类别。例如，一条验证记录的 $\eta_i=0.08744$，代入式 (5) 得 $p_i=0.52185$。模型把它归入高收入组，原始标签却为 0。后文把这样的记录计为误报。

随机森林把多棵树的预测合在一起 [11]。回归树按面积等特征逐次拆分训练样本。设一次拆分得到左右两组 A_L、A_R。由式 (3) 可知，各组的最佳常数预测分别为本组均值。树在候选拆分中选择使下式最小的特征和分界值：

$$\sum_{i\in A_L}(y_i-\bar{y}_L)^2+\sum_{i\in A_R}(y_i-\bar{y}_R)^2. \tag{7}$$

每棵树从训练集有放回抽样，式 (7) 按抽中的次数计数。实验使用 120 棵树，最大深度为 12，每个叶节点至少有 5 条训练记录。回归时对各树的预测值取平均。分类时以基尼不纯度选择拆分，再对各树给出的正类概率取平均。上述单次划分复核固定超参数；扩展搜索协议见本节前文。

记 $\mathcal{V}$ 为验证样本，n_V 为样本数，$\hat{y}_i$ 为未使用该记录训练时得到的预测。均方根误差（RMSE）与预测目标单位相同：

$$\mathrm{RMSE} = \sqrt{\frac{1}{n_V}\sum_{i\in\mathcal{V}}(y_i-\hat{y}_i)^2}, \qquad R^2 = 1 - \frac{\sum_{i\in\mathcal{V}}(y_i-\hat{y}_i)^2}{\sum_{i\in\mathcal{V}}(y_i-\bar{y}_V)^2}. \tag{8}$$

平方会给大误差更高的权重。平均绝对误差（MAE）则直接平均每条记录的绝对误差。R^2 的分母使用验证样本的均值 $\bar{y}_V$ 来度量实际结果的离散程度。用常数做预测时仍只使用训练均值 $\bar{y}_T$。

详细推导、预处理和逐条计算示例见附录 A，统计分母与分析参数见附录 B。

附录 A
数学推导与计算示例

本附录展开正文模型和评价指标的计算过程。一元回归的截距与斜率记作 b_0, b_1，对应正文的 a, b；$\mathcal{T}$ 和 $\mathcal{V}$ 分别表示训练集与验证集。

A. 从均值到一元回归

设训练数据有 n 套房屋，成交价为 $y_1, \dots, y_n$。先用常数 c 预测每套房屋。第 i 套的误差为 $y_i - c$。误差有正有负，直接相加会互相抵消；平方后每项均为非负，较大的误差也会受到更高惩罚。总平方误差为

$$L(c) = \sum_{i=1}^{n} (y_i - c)^2. \tag{A.1}$$

对 c 求导：

$$\frac{\mathrm{d}L}{\mathrm{d}c} = \sum_{i=1}^{n} 2(y_i - c)(-1) = -2 \sum_{i=1}^{n} (y_i - c).$$

令导数等于零，得到 $\sum_i y_i - nc = 0$，于是

$$\hat{c} = \bar{y} = \frac{1}{n} \sum_{i=1}^{n} y_i. \tag{A.2}$$

二阶导数为 $2n > 0$，所以这里取得最小值。均值基线由此得到：如果只允许输出一个常数，训练均价是使训练平方误差最小的选择。

现在加入面积 x_i，用

$$\hat{y}_i = b_0 + b_1 x_i \tag{A.3}$$

预测成交价。b_0 是截距，b_1 是斜率；面积增加一个单位，拟合价格改变 b_1 个价格单位。我们选择使下式最小的两个参数：

$$L(b_0, b_1) = \sum_{i=1}^{n} (y_i - b_0 - b_1 x_i)^2. \tag{A.4}$$

先对截距求偏导。此时把 b_1 看成固定数：

$$\frac{\partial L}{\partial b_0} = -2 \sum_{i} (y_i - b_0 - b_1 x_i) = 0.$$

移项并除以 n，得到

$$\hat{b}_0 = \bar{y} - \hat{b}_1 \bar{x}. \tag{A.5}$$

所以拟合直线通过样本均值点 $(\bar{x}, \bar{y})$。把式(A.5)代回残差，有

$$y_i - \hat{b}_0 - b_1 x_i = (y_i - \bar{y}) - b_1 (x_i - \bar{x}).$$

接着对 b_1 求导：

$$\frac{\mathrm{d}L}{\mathrm{d}b_1} = -2\sum_i (x_i - \bar{x})\{(y_i - \bar{y}) - b_1(x_i - \bar{x})\} = 0,$$

$$\hat{b}_1 \sum_i (x_i - \bar{x})^2 = \sum_i (x_i - \bar{x})(y_i - \bar{y}).$$

只要面积不全部相同，分母为正，从而

$$\hat{b}_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}, \qquad \hat{b}_0 = \bar{y} - \hat{b}_1 \bar{x}. \tag{A.6}$$

分子衡量面积与价格如何共同偏离各自均值；分母衡量面积自身的变化。如果大面积房屋经常高于平均价格，小面积房屋经常低于平均价格，分子的乘积通常为正，斜率也倾向于为正。

取上传房价表中 Id 为 1、2、3 的记录。它们只用于展示算式，正式模型仍使用后文的训练与验证划分。先求两个均值：

Id	地上居住面积 x_i（平方英尺）	成交价 y_i（美元）
1	1,710	208,500
2	1,262	181,500
3	1,786	223,500

表 A.1 三条教学计算记录，来自上传的 train.csv。

$$\bar{x} = \frac{1710 + 1262 + 1786}{3} = 1586, \qquad \bar{y} = \frac{208500 + 181500 + 223500}{3} = 204500.$$

去均值后，面积偏差为 $(124, -324, 200)$，价格偏差为 $(4000, -23000, 19000)$。因此

$$\sum_i (x_i - \bar{x})(y_i - \bar{y}) = 124 \times 4000 + (-324) \times (-23000) + 200 \times 19000$$

$$= 11\,748\,000,$$

$$\sum_i (x_i - \bar{x})^2 = 124^2 + (-324)^2 + 200^2 = 160\,352.$$

代回式(A.6)，得到

$$\hat{b}_1 = 73.2638, \qquad \hat{b}_0 = 204500 - 73.2638 \times 1586 \approx 88303.58.$$

这三条记录的拟合直线为

$$\hat{y} = 88303.58 + 73.2638x. \tag{A.7}$$

参数用原始单位表达：面积多一个平方英尺，拟合价格增加约 73.26 美元。这个斜率来自三条记录，正式房价模型使用后文的完整训练集。计算脚本核对了闭式解与最小二乘数值解，二者一致。

计算记录：tables/teaching/ols_three_rows.csv；tools/teaching_calculations.py

残差 $e_i = y_i - \hat{y}_i$ 表示实际价格与拟合价格的差。截距和斜率的一阶条件分别给出

$$\sum_i e_i = 0, \qquad \sum_i x_i e_i = 0. \tag{A.8}$$

这两式是训练样本上最小二乘解的代数性质。它们说明，继续给截距或斜率加一个微小改动，已经不能一阶降低平方误差。模型应用到新数据后，残差均值可以偏离零；因此训练拟合仍需用留出的样本检查。

B. 多元房价回归

正式模型使用面积以外的房屋特征。拟合之前，先把数据分成训练集 $\mathcal{T}$ 和验证集 $\mathcal{V}$。训练集决定参数，验证集用于检查模型对未参与拟合记录的预测。后文用 $n_T = |\mathcal{T}|$、$n_V = |\mathcal{V}|$ 表示两部分的样本数。

房价主配置按固定随机种子 42 划分，1,168 条用于训练，292 条用于验证。同一划分中的线性回归和随机森林使用相同的行。这样比较误差时，两种算法面对的是同一批房屋。基准预测则把每套验证房屋都预测为训练均价 181,441.54 美元。

数据预处理也从训练集学习。比如，填补面积缺失值所用的中位数，必须由训练记录计算。验证集沿用这个值；新房屋也沿用它。scikit-learn developers [12]将这种先划分、再拟合预处理的做法列为防止信息泄漏的基本步骤。

对数值特征 j，先从训练集的非缺失值计算中位数 m_j，把缺失值替换为 m_j，得到 $\tilde{x}_{ij}$。随后计算

$$\mu_j = \frac{1}{n_T}\sum_{i\in\mathcal{T}} \tilde{x}_{ij}, \qquad s_j = \sqrt{\frac{1}{n_T}\sum_{i\in\mathcal{T}} (\tilde{x}_{ij}-\mu_j)^2}. \tag{A.9}$$

标准化后的值为

$$z_{ij} = \frac{\tilde{x}_{ij}-\mu_j}{s_j}. \tag{A.10}$$

$z_{ij}=1$ 表示该记录比训练均值高一个训练标准差。本项目的 StandardScaler 使用分母 n_T；当训练方差为零时，程序采用缩放因子 1，避免除以零。训练子集中全缺失的特征会被拒绝。

社区是类别，不能把 “Blmngtn、CollgCr、Sawyer” 直接当作有距离关系的数字。独热编码为每个类别建立一个取值为 0 或 1 的变量。例如，$D_{i,\text{CollgCr}}=1$ 表示第 i 套房屋属于 CollgCr，否则为 0。因为各类别指示变量之和恒为 1，与截距重复，模型保留一个参考类别，其余类别各占一列。

房价主配置有 5 个数值变量，训练集有 25 个社区类别，参考类别是 Blmngtn。因此模型使用 5 个数值列和 24 个社区列，共 29 个斜率参数，另加截距。分类缺失值先记作单独类别 __missing__；每个分类字段最多保留 30 个编码类别。验证时遇到训练中未见的类别，编码器给出全零，并保存提示。

把一个样本的编码结果记为 $\mathbf{z}_i = (z_{i1},\dots,z_{ip})^{\mathsf{T}}$。多元模型为

$$\hat{y}_i = \beta_0 + \sum_{j=1}^{p} \beta_j z_{ij}. \tag{A.11}$$

写成矩阵时，第一列放常数 1，后面放编码特征：

$$X = \begin{pmatrix} 1 & z_{11} & \cdots & z_{1p} \\ 1 & z_{21} & \cdots & z_{2p} \\ \vdots & \vdots & & \vdots \\ 1 & z_{n_T1} & \cdots & z_{n_Tp} \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_{n_T} \end{pmatrix}.$$

于是全部预测为 $X\boldsymbol{\beta}$，平方误差可以写成

$$L(\boldsymbol{\beta}) = (\mathbf{y} - X\boldsymbol{\beta})^{\mathsf{T}}(\mathbf{y} - X\boldsymbol{\beta}) \tag{A.12}$$

$$= \mathbf{y}^{\mathsf{T}}\mathbf{y} - 2\boldsymbol{\beta}^{\mathsf{T}}X^{\mathsf{T}}\mathbf{y} + \boldsymbol{\beta}^{\mathsf{T}}X^{\mathsf{T}}X\boldsymbol{\beta}. \tag{A.13}$$

第一项不含参数，导数为零；后两项分别给出 $-2X^{\mathsf{T}}\mathbf{y}$ 和 $2X^{\mathsf{T}}X\boldsymbol{\beta}$。令梯度为零，得到正规方程

$$X^{\mathsf{T}}X\hat{\boldsymbol{\beta}} = X^{\mathsf{T}}\mathbf{y}. \tag{A.14}$$

X 满列秩时，$X^{\mathsf{T}}X$ 可逆，从而

$$\hat{\boldsymbol{\beta}} = (X^{\mathsf{T}}X)^{-1}X^{\mathsf{T}}\mathbf{y}. \tag{A.15}$$

式(A.15)说明解的形式。实际 LinearRegression 使用数值最小二乘算法求解，无需显式构造逆矩阵[10]。若特征存在精确线性关系，系数可能不唯一；接近线性相关时，系数也可能对样本变化敏感。

二阶导数为 $2X^{\mathsf{T}}X$。任取向量 $\mathbf{v}$，有

$$\mathbf{v}^{\mathsf{T}}(2X^{\mathsf{T}}X)\mathbf{v} = 2\|X\mathbf{v}\|^2 \geq 0.$$

所以平方误差是凸函数；满列秩时不等式对非零 $\mathbf{v}$ 严格成立，最小值唯一。式(A.14)也可写成 $X^{\mathsf{T}}\hat{\mathbf{e}} = 0$，即训练残差与每一列特征正交。

数值特征的拟合项是 $\beta_j z_j$。代入式(A.10)：

$$\beta_j z_j = \frac{\beta_j}{s_j}\tilde{x}_j - \frac{\beta_j \mu_j}{s_j}.$$

因此原始单位下的斜率是 β_j/s_j，数值部分换回原始单位后的截距是

$$\beta_0^{\text{raw}} = \beta_0 - \sum_{j\in\text{数值列}} \frac{\beta_j \mu_j}{s_j}. \tag{A.16}$$

类别编码保持不变。房价主配置中，面积系数为 24,586.18，面积训练标准差为 524.2081 平方英尺，因此

$$\frac{24586.18}{524.2081} = 46.9016 \text{ 美元/平方英尺}.$$

其余编码特征相同时，面积增加 100 平方英尺，预测价格增加约 4,690.16 美元。这是模型给出的价格差。实际改造收益还取决于其他因素和改造成本。

保存的验证记录 house:00000892 的实际成交价为 154,500 美元。由训练阶段保存的均值、标准差和系数，可以逐项重建预测。把最后一列相加，得到 141,984.82 美元；实际价减预测价，残差为 12,515.18 美元。脚本还用保存的参数重建了全部 292 条房价验证预测，最大绝对差小于 6×10^{-11} 美元。

计算记录：tables/teaching/house_primary_linear_contributions.csv；verification/editorial/teaching_calculations.json

项目	编码值	系数	对预测的贡献（美元）
截距	1	158,544.58	158,544.58
整体质量	−0.088934	21,483.32	−1,910.59
居住面积	−0.876372	24,586.18	−21,546.65
建成年份	−0.259789	8,269.93	−2,148.44
地下室面积	−0.006292	8,908.75	−56.05
车位数	−1.056544	9,474.81	−10,010.56
Sawyer 社区	1	19,112.54	19,112.54

表 A.2 仅列非零项。展示值经过四舍五入，重算使用完整精度。

C. 收入分类与逻辑回归

Adult 的目标只有两种取值：超过年收入 5 万美元记为 1，否则记为 0。我们希望得到 $p_i = P(y_i = 1 \mid \mathbf{z}_i)$。线性组合 $\eta_i = \beta_0 + \mathbf{z}_i^{\mathsf{T}}\boldsymbol{\beta}$ 可以取任意实数，需要一个映射把它变成 0 到 1 之间的概率。

逻辑回归令概率的对数几率随特征线性变化：

$$\log \frac{p_i}{1-p_i} = \eta_i. \tag{A.17}$$

几率 $p/(1-p)$ 比较“发生”和“不发生”的概率。例如，$p = 0.8$ 时几率为 4；$p = 0.2$ 时几率为 $1/4$。对式(A.17)两边取指数，再把 p_i 移到一侧：

$$\begin{aligned} \frac{p_i}{1-p_i} &= e^{\eta_i}, \\ p_i &= e^{\eta_i}(1-p_i), \\ p_i(1+e^{\eta_i}) &= e^{\eta_i}. \end{aligned}$$

所以

$$p_i = \sigma(\eta_i) = \frac{1}{1+e^{-\eta_i}}. \tag{A.18}$$

$\eta_i = 0$ 时 $p_i = 0.5$；η_i 越大，概率越接近 1。项目在概率达到 0.5 时预测为高收入类别。

对一个实际结果为 y_i 的样本，伯努利概率可统一写成

$$P(y_i \mid \mathbf{z}_i) = p_i^{y_i}(1-p_i)^{1-y_i}. \tag{A.19}$$

若 $y_i = 1$，它等于 p_i；若 $y_i = 0$，它等于 $1-p_i$。在模型采用的条件独立假设下，训练样本的似然为

$$\mathcal{L}(\boldsymbol{\beta}) = \prod_{i \in \mathcal{T}} p_i^{y_i}(1-p_i)^{1-y_i}.$$

取对数将乘积变成求和；再取负号，把最大化似然写成最小化损失：

$$\ell(\boldsymbol{\beta}) = -\sum_{i \in \mathcal{T}} \{ y_i \log p_i + (1-y_i)\log(1-p_i) \}. \tag{A.20}$$

实际为高收入的样本，如果预测概率很小，$-\log p_i$ 就很大。实际为低收入的样本，如果预测概率很大，$-\log(1-p_i)$ 同样很大。损失函数据此惩罚自信但错误的预测。

记 $\mathbf{x}_i = (1, \mathbf{z}_i^{\mathsf{T}})^{\mathsf{T}}$，并把截距并入参数向量。先对 sigmoid 求导：

$$\begin{aligned}\frac{\mathrm{d}p_i}{\mathrm{d}\eta_i} &= \frac{e^{-\eta_i}}{(1+e^{-\eta_i})^2} \\ &= \frac{1}{1+e^{-\eta_i}}\left(1 - \frac{1}{1+e^{-\eta_i}}\right) = p_i(1-p_i).\end{aligned}$$

单个样本的负对数似然对 p_i 的导数为

$$\frac{\partial \ell_i}{\partial p_i} = -\frac{y_i}{p_i} + \frac{1-y_i}{1-p_i} = \frac{p_i - y_i}{p_i(1-p_i)}.$$

链式法则把它与 $\mathrm{d}p_i/\mathrm{d}\eta_i$ 相乘，得到 $\partial \ell_i/\partial \eta_i = p_i - y_i$。又因为 $\eta_i = \mathbf{x}_i^{\mathsf{T}}\boldsymbol{\beta}$，所以

$$\nabla \ell(\boldsymbol{\beta}) = X^{\mathsf{T}}(\mathbf{p} - \mathbf{y}). \tag{A.21}$$

梯度仍由预测与实际的差组成，只是这里比较的是概率与 0/1 标签。概率本身含有参数，无法像线性回归那样直接移项得到一个固定矩阵的逆，需要迭代求解。

实现采用 C=1 的逻辑回归，lbfgs 求解，最大迭代次数为 1,500。按照所用 scikit-learn 1.8 的定义，在没有样本权重和类别权重时，等价目标为 [10]

$$J(\boldsymbol{\beta}) = \frac{1}{n_T}\sum_{i \in \mathcal{T}} \ell_i + \frac{1}{2C n_T}\sum_{j=1}^{p} \beta_j^2. \tag{A.22}$$

式(A.22)是正文式(6)除以 n_T 后的形式，两者得到相同的最优参数。惩罚项只作用于斜率，截距不受惩罚。C 越小，惩罚越强。令 $D = \mathrm{diag}(0, 1, \ldots, 1)$，则

$$\nabla J = \frac{X^{\mathsf{T}}(\mathbf{p} - \mathbf{y})}{n_T} + \frac{D\boldsymbol{\beta}}{C n_T}. \tag{A.23}$$

再求一次导数，令 $W = \mathrm{diag}\{p_i(1-p_i)\}$，得到

$$\nabla^2 J = \frac{X^{\mathsf{T}} W X}{n_T} + \frac{D}{C n_T}. \tag{A.24}$$

两项都是半正定矩阵，因此目标函数为凸函数。计算脚本用数值差分检查了式(A.23)与式(A.24)，最大绝对误差均小于 2×10^{-11}。这项核对使用四行固定数值输入，结果单独保存。

对标准化特征，β_j 表示该特征增加一个训练标准差时，对数几率的变化。由式(A.17)可得，相应几率乘以 e^{β_j}。若需要原始单位下的比较，把系数除以训练标准差即可。

Adult 主配置的年龄系数为 0.42015，年龄训练标准差为 13.54748 岁，所以每增加一岁，模型对数几率增加约 0.03101。概率变化还取决于起点。由链式法则，年龄的局部概率变化率为

$$\frac{\partial p}{\partial \mathrm{age}} = p(1-p)\frac{0.42015}{13.54748}. \tag{A.25}$$

同一个系数在 p 接近 0.5 时对应较大的概率变化，在 p 接近 0 或 1 时对应较小的变化。

保存的验证记录 adult:train:00000001 的线性预测值为 $\eta = 0.08743669$。代入 sigmoid：

$$\hat{p} = \frac{1}{1+e^{-0.08743669}} = 0.52184526.$$

阈值为 0.5，所以模型把这条记录预测为高收入；实际标签为 0，这是一条假阳性。讲解计算重建了全部 6,512 条逻辑回归验证概率，最大绝对差小于 4×10^{-16}。

计算记录：tables/teaching/adult_primary_logistic_contributions.csv；verification/editorial/teaching_calculations.json

这些系数描述其他特征相同时的样本关联。Adult 使用观察数据，估计教育、职业或婚姻状态的因果效果需要另外的研究设计。各项比例和模型使用未按 fnlwgt 加权的样本。

D. 回归树与随机森林

社区均价给每个社区内的房屋一个相同预测。回归树也把样本分成若干组，但分组规则由训练数据选择。例如，它可以先按面积是否超过某个值分成两组，再在组内按房屋质量继续分组。

对节点中的训练集合 A，先预测其平均值 $\bar{y}_A$。若用特征 j 和阈值 t 分组，得到

$$A_L(j,t) = \{i \in A : x_{ij} \le t\}, \qquad A_R(j,t) = \{i \in A : x_{ij} > t\}.$$

候选分裂的平方误差为

$$Q(j,t) = \sum_{i \in A_L} (y_i - \bar{y}_{A_L})^2 + \sum_{i \in A_R} (y_i - \bar{y}_{A_R})^2. \tag{A.26}$$

程序考察候选特征和阈值，选择使 $Q(j,t)$ 最小的组合，然后在子节点重复。每一组的预测取均值，是因为式(A.2)已证明均值使组内平方误差最小。最终停止分裂的组称为叶节点，新房屋沿分裂规则到达某个叶节点，获得该节点的预测。

这是一种逐节点选择的贪心算法：每一步挑当前最合适的分裂。树越深，可形成的组越细；也越容易把训练样本的偶然差异记下来。项目把最大深度固定为 12，并设置叶节点最少样本数为 5[13]。

在 Adult 中，一个叶节点给出该节点高收入记录的比例。节点中正类比例为 p_A 时，基尼不纯度为

$$G(A) = 1 - p_A^2 - (1 - p_A)^2 = 2p_A(1 - p_A). \tag{A.27}$$

当所有记录都属于同一类时，$G(A) = 0$；两类各占一半时，$G(A) = 0.5$。选择分裂时，分类树最小化左右节点的加权不纯度：

$$Q_G(j,t) = \frac{|A_L|}{|A|} G(A_L) + \frac{|A_R|}{|A|} G(A_R). \tag{A.28}$$

因此一个分裂的作用，是让两个子节点中的类别更集中。采用 bootstrap 抽样时，重复抽中的记录带有抽样次数权重，节点均值、比例与不纯度按相应权重计算。

一棵树的分裂可能对训练样本变化敏感。随机森林反复从训练数据有放回抽样，每份样本训练一棵树，然后把预测合起来。回归森林取树预测的平均：

$$\hat{f}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^{B} \hat{f}_b(\mathbf{x}), \qquad B = 120. \tag{A.29}$$

分类森林平均各树叶节点中的正类概率，再按 0.5 阈值给出类别。scikit-learn 的实现使用概率平均，而非先把每棵树变成硬类别再投票 [14]。

求平均为什么可能更稳定，可以用一个简化的方差计算理解。假设对固定输入 $\mathbf{x}$，每棵树预测的方差都是 σ^2，任意两棵树的相关系数都是 ρ。于是

$$\mathrm{Var}\left(\frac{1}{B}\sum_b \hat{f}_b\right) = \frac{1}{B^2}\left[B\sigma^2 + B(B-1)\rho\sigma^2\right] \tag{A.30}$$

$$= \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2. \tag{A.31}$$

推导把方差之和与两两协方差分开。B 增大时，第二项缩小；如果各树高度相关，第一项仍然存在。因此增加树数带来的稳定性取决于树之间的相关程度。式(A.31)用来解释树数和相关程度怎样影响平均预测的方差。

本项目回归森林和分类森林都使用 120 棵树、深度 12、叶节点最少样本数 5、单线程和随机种子 42。两类森林采用的候选特征数不同：回归森林沿用 max_features=1.0，每个节点考察全部编码特征 [15]；分类森林沿用 max_features="sqrt"，每次从编码特征中抽取约平方根数量的候选列 [14]。

因此，当前回归森林的随机变化主要来自 bootstrap 样本，分类森林还对节点候选特征随机抽样。森林沿用与线性模型相同的预处理；标准化统一了输入处理；树的分裂也可以直接使用原始数值。

项目采用验证集置换重要性。先计算原始验证误差；再随机打乱某一特征列，保持其他列与模型不变，观察误差怎样变化。对回归，特征 j 的第 r 次重要性为

$$I_j^{(r)} = \mathrm{RMSE}(y_V, \hat{f}(X_V^{\pi_{jr}})) - \mathrm{RMSE}(y_V, \hat{f}(X_V)). \tag{A.32}$$

分类使用打乱前 AUC 减打乱后 AUC。程序重复 3 次，报告均值和标准差。较大的正值表明，在当前验证样本和当前模型中，破坏这一列与其他信息的对应关系会明显降低预测表现。

相关特征可能互相替代，所以某列的重要性较低，仍可能与目标有关；少数置换还可能偶然改善指标，得到负值。三次置换的标准差描述重复打乱这一列时的变化。总体置信区间和因果效应需要另外估计。

E. 预测评价

训练时，程序已经用实际结果选择了参数。在这些样本上误差小，可能只是参数适应了训练数据。验证集的用途，是让拟合完成的模型预测另一批记录，再将预测与实际结果比较。

本项目先确定样本划分，再计算插补值、标准化参数和类别编码。验证记录只经过训练时确定的变换，不能参与这些参数的估计。比较两个算法时，目标、特征和验证记录保持相同；否则误差的差异可能来自样本变化。

记验证集大小为 n_V，第 i 条记录的实际值为 y_i，预测值为 $\hat{y}_i$，误差为 $e_i = y_i - \hat{y}_i$。正误差表示低估，负误差表示高估。如果直接平均误差，高估与低估会相互抵消。平均绝对误差因此先去掉符号：

$$\mathrm{MAE} = \frac{1}{n_V}\sum_{i\in\mathcal{V}} |e_i|. \tag{A.33}$$

房价以美元记录，所以 MAE 也以美元计量。它回答的是“每套房屋的预测与实际成交价，平均相差多少”。

均方根误差先平方、平均，再开平方：

$$\mathrm{RMSE} = \sqrt{\frac{1}{n_V}\sum_{i\in\mathcal{V}} e_i^2}. \tag{A.34}$$

平方使较大的误差占更大比重；开平方把单位恢复到目标变量的原单位。由 $\frac{1}{n}\sum a_i^2 \geq (\frac{1}{n}\sum a_i)^2$，取 $a_i = |e_i|$ 可得 RMSE $\geq$ MAE。两者差距较大时，可以再查看逐条误差，找出影响 RMSE 的记录。

R^2 将模型平方误差与验证集围绕自身均值的波动比较：

$$R^2 = 1 - \frac{\sum_{i\in\mathcal{V}}(y_i - \hat{y}_i)^2}{\sum_{i\in\mathcal{V}}(y_i - \bar{y}_V)^2}, \qquad \bar{y}_V = \frac{1}{n_V}\sum_{i\in\mathcal{V}} y_i. \tag{A.35}$$

预测完全正确时 $R^2 = 1$；误差平方和等于分母时 $R^2 = 0$；比该参照更差时 $R^2 < 0$。在验证集上，R^2 可以为负。这个定义要求验证目标并非全部相同。

新房屋的成交价尚未发生，模型无法事先取得新样本的目标均值。可实际使用的常数预测是训练均值 $\bar{y}_T$：对每条验证记录都预测同一个 $\bar{y}_T$。其误差为

$$\mathrm{RMSE}_{\mathrm{mean}} = \sqrt{\frac{1}{n_V}\sum_{i\in\mathcal{V}}(y_i - \bar{y}_T)^2}.$$

它与式(A.35)分母中的验证均值有不同作用。令 $y_i - \bar{y}_T = (y_i - \bar{y}_V) + (\bar{y}_V - \bar{y}_T)$，展开平方并利用 $\sum_{i\in\mathcal{V}}(y_i - \bar{y}_V) = 0$，得到

$$\sum_{i\in\mathcal{V}}(y_i - \bar{y}_T)^2 = \sum_{i\in\mathcal{V}}(y_i - \bar{y}_V)^2 + n_V(\bar{y}_V - \bar{y}_T)^2. \tag{A.36}$$

所以，训练均值基线通常比式(A.35)的分母多出一项均值偏移。报告时分别标明训练均值基线和验证目标的波动。

Adult 的预测概率以 0.5 为阈值。实际为 1、预测为 1 记为真正例 TP；实际为 0、预测为 1 记为假正例 FP；实际为 1、预测为 0 记为假负例 FN。逻辑回归在保存的 6,512 条验证记录中得到：精

	预测为 0	预测为 1
实际为 0	4,543	401
实际为 1	719	849

确率衡量预测为正的记录中有多少确实为正；召回率衡量所有实际正例中找到了多少：

$$P = \frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FP}}, \qquad R = \frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FN}}. \tag{A.37}$$

F1 是二者的调和平均：

$$F_1 = \frac{2PR}{P+R} = \frac{2\mathrm{TP}}{2\mathrm{TP}+\mathrm{FP}+\mathrm{FN}} \tag{A.38}$$

$$= \frac{2\times 849}{2\times 849 + 401 + 719} = 0.602555\ldots. \tag{A.39}$$

因此 F1 的数值可以直接从混淆矩阵复算。改变阈值会改变哪些记录被判为正，进而改变 TP、FP、FN；本次基准没有用验证集再挑选阈值。

计算记录：artifacts/benchmarks/2add40f7ab234ff49ea10877d927ea07/confusion.csv

ROC AUC 评价正例与负例的排序。令正例集合为 V_+、负例集合为 V_-，其大小分别为 n_+、n_-。AUC 可以写成

$$\mathrm{AUC} = \frac{1}{n_+ n_-} \sum_{i \in V_+} \sum_{j \in V_-} \left[\mathbf{1}(\hat{p}_i > \hat{p}_j) + \tfrac{1}{2} \mathbf{1}(\hat{p}_i = \hat{p}_j) \right]. \tag{A.40}$$

对每一对正、负记录，正例概率更大得 1 分，并列得半分。平均后，就得到模型把正例排在负例之前的比例。AUC 使用整套排序，F1 使用某个阈值后的类别，因此两个模型在这两项指标上的名次可以不同。

Brier 分数直接比较概率与实际标签：

$$\mathrm{Brier} = \frac{1}{n_V} \sum_{i \in \mathcal{V}} (y_i - \hat{p}_i)^2. \tag{A.41}$$

验证对数损失则把式(A.20)应用于验证集并取平均，不含训练惩罚项。两项概率误差越低越好。数值计算对极端概率按软件实现截断，以避免 $\log 0$。概率校准要另外比较各概率区间的预测值和实际频率，本次实验报告整体概率误差。

这些指标都由保存的逐行预测计算。项目保留了独立复算结果，用于检查行号对齐、分母和概率并列的处理。本文比较固定验证样本上的误差，算法差异的显著性尚未检验。

F. 本地字段检索

检索程序负责查找问题需要的字段说明。它将数据说明、字段名称、中文释义、示例取值和方法说明分别保存成短文档。房价检索索引实际包含 90 份文档，每份都有固定标识，例如 house:field:Neighborhood。

当前检索器使用字符 TF–IDF。字符串连续取长度为 2、3、4 的片段，例如“平均成交价”可产生“平均”“均成”“成交”“交价”，以及更长的连续片段。英文先转成小写。采用字符片段后，中文查询不需要先分词，英文列名的部分重合也可以参与匹配。

它适合字段名、常见说法和已整理的中文释义。对索引中未出现的同义说法，词面匹配可能很弱。因此字段释义是否写清楚，会影响哪些信息能被检索到。

用 c_{td} 表示字符片段 t 在文档 d 中出现的次数。若只看出现次数，长文档或反复出现的词容易占优势。项目启用次线性词频，使用

$$\mathrm{tf}(t,d) = \begin{cases} 1 + \log c_{td}, & c_{td} > 0, \\ 0, & c_{td} = 0. \end{cases} \tag{A.42}$$

对数使重复出现的贡献逐渐减小。另一个问题是：某片段如果在所有说明中都出现，它就不太能区分文档。设文档总数为 N，包含片段 t 的文档数为 $\mathrm{df}(t)$，平滑逆文档频率为

$$\mathrm{idf}(t) = 1 + \log \frac{N+1}{\mathrm{df}(t)+1}. \tag{A.43}$$

片段越少见，IDF 越大；所有文档都出现时，IDF 为 1。加 1 是当前实现的平滑方式。二者相乘得到未归一化权重

$$w_{td} = \mathrm{tf}(t,d)\,\mathrm{idf}(t).$$

以上定义与项目使用的 sublinear_tf=True、smooth_idf=True 对应 [16]。

把全部片段的权重排成向量 $\mathbf{w}_d$。长文档可能具有更多非零项，直接点积容易受到长度影响。检索器先除以向量长度：

$$\mathbf{v}_d = \frac{\mathbf{w}_d}{\|\mathbf{w}_d\|_2}. \tag{A.44}$$

查询也用同一个词表和同一组 IDF 变换为 $\mathbf{v}_q$。两个非零单位向量的点积等于余弦相似度：

$$s(q,d) = \mathbf{v}_q^{\top}\mathbf{v}_d = \frac{\mathbf{w}_q^{\top}\mathbf{w}_d}{\|\mathbf{w}_q\|_2\|\mathbf{w}_d\|_2}. \tag{A.45}$$

片段重合越多、相应权重越大，相似度通常越高。如果查询中的片段均未进入词表，变换结果为零向量，程序不返回正相似度文档。

对 “CollgCr 社区房屋的平均成交价是多少?”，本次实际检索的前六条如下。表中分数由执行结果保留六位小数。前两条直接对应问题所需的列，后面几条只有较弱的词面匹配。检索返回候选说

说明文档	相似度	内容
house:field:Neighborhood	0.176436	社区字段
house:field:SalePrice	0.070664	成交价字段
house:scope	0.058073	房价数据说明
house:field:ScreenPorch	0.037493	纱窗门廊字段
house:field:OverallCond	0.032570	整体状况字段
house:field:RoofMatl	0.032279	屋顶材料字段

明，生成方案时还要结合问题和完整字段模式判断哪些列应被采用。相似度 0.176436 是式(A.45)得到的词面匹配分数。

计算记录：verification/editorial/worked_retrieval.json

DeepSeek API 收到当前数据集的字段名与类型、检索到的说明、用户问题以及必要的上一轮分析方案。它输出目标字段、筛选条件、算法等 JSON 参数。程序检查参数格式与字段是否存在，用户核对后再运行相应计算函数。结果解释由实际指标和固定文字模板组成。

检索增强生成的基本思路是让生成过程使用外部查得的信息 [2]。这里的外部信息来自本机说明文件；数值计算仍读取完整筛选样本。检索使用字符 TF–IDF。

检索是否找到需要的列、语言模型是否理解了提问、计算函数是否算对，是三个可以分别检查的问题。旧版的 16 道固定检索题全部在前六条命中目标文档，平均倒数排名为 0.96875。其定义是

$$\mathrm{MRR} = \frac{1}{Q}\sum_{q=1}^{Q}\frac{1}{r_q},$$

其中 r_q 为首条目标文档的排名，未命中按 0 分处理。题目多数含有原字段名。自由中文提问与 API 方案质量的后续评价办法统一见附录 D-E。

附录 B
统计计算与分析参数

A. 社区均价

以房价表为例，用户问：“CollgCr 社区房屋的平均成交价是多少？”表中每一行对应一条房屋记录，Neighborhood 保存社区类别，SalePrice 保存成交价。这个问题给出了筛选条件和统计方法：筛选社区等于 CollgCr 的记录，对成交价求平均。

设第 i 条记录的成交价为 y_i。用集合

$$S = \{i : \text{Neighborhood}_i = \text{CollgCr},\ y_i \text{ 有记录}\} \tag{B.1}$$

表示参与计算的行，$n_S = |S|$ 表示行数。求和符号 $\sum_{i\in S} y_i$ 的意思是，把这些行的成交价逐个加起来。因此均价为

$$\bar{y}_S = \frac{1}{n_S}\sum_{i\in S} y_i. \tag{B.2}$$

本次上传数据中，$n_S = 150$，成交价合计为 29,694,866 美元，代入可得

$$\bar{y}_S = \frac{29\,694\,866}{150} = 197\,965.77 \text{ 美元}.$$

程序保存了参与计算的记录和汇总结果。全部 1,460 条房屋记录的均价为 180,921.20 美元。两个均价对应不同样本，解释社区差异时还需要考虑房屋面积、质量等构成。

计算记录：tables/teaching/collgcr_members.csv；verification/editorial/worked_aggregate.json

均值的分母是该字段的有效记录数。房价表共 1,460 行，但临街长度 LotFrontage 只有 1,201 条非缺失记录。直接求它的均值时，分母应为 1,201；除以 1,460 会把没有记录的长度当作零。

程序在汇总结果中同时保存 n_rows 与 n_valid。前者是筛选后的行数，后者是当前统计字段的非缺失数。CollgCr 的 150 条记录都有成交价，因此两个数都是 150。网页即使只显示前 20 个结果组，计算仍使用各组全部有效记录。

高收入比例也可以写成均值。令 $y_i = 1$ 表示年收入超过 5 万美元，$y_i = 0$ 表示未超过，某组的样本比例就是

$$\hat{p}_S = \frac{\sum_{i\in S} y_i}{n_S}. \tag{B.3}$$

分子数出高收入记录，分母数出该组有效记录。Adult 的 income_gt_50k 是这样构造的二元变量。数据没有个人的具体收入金额 [4]。

B. 从问题到计算

“社区”“成交价”是中文表达，表格使用的字段名是 Neighborhood 和 SalePrice。本地说明库把这些名称和释义放在一起。收到问题后，检索程序找出相关说明，连同当前表格结构交给语言模型。语言模型据此填写分析参数，计算程序再读取表格。

这一设计采用检索增强生成，即 RAG：生成答案或分析方案时，把检索到的资料加入模型输入。Lewis et al. [2]讨论了将外部检索信息与生成模型结合的方法。TableLab 在本地检索字段和方法说明，通过 DeepSeek API 生成分析方案，随后在本机执行统计与模型训练。

以刚才的均价问题为例，计算参数的主要内容如下。本例使用人工给定并已执行的参数。

```
{
  "dataset": "house",
  "operation": "aggregate",
  "columns": ["SalePrice"],
  "filters": [
    {"column": "Neighborhood", "op": "eq", "value": "CollgCr"}
  ],
  "group_by": [],
  "metric": "mean"
}
```

其中 eq 表示等于；columns 指定要计算的列；metric 指定求均值。这些参数可以直接与原问题逐项核对。字段不存在、目标与算法不匹配，或者必要条件没有给出时，程序返回具体原因。

本地检索返回的是说明文字。例如，它告诉模型 SalePrice 的含义，却不提供 CollgCr 的所有成交记录。数值执行器根据参数重新筛选完整表格，再按式(B.2)求平均。这使统计分母由数据条件决定。

一次成功计算会留下问题、参数、检索片段、结果表和执行代码。用户可以检查均价来自哪些行，也可以改变社区重新计算。当前网页采用两次操作：先生成参数，核对后再点击执行。语言模型只输出参数，执行器使用已经写好的统计和建模函数。

社区均价描述已记录房屋的平均水平。对一套新房屋估价，需要利用它的面积、质量、建成年份等信息。最简单的办法是让所有新房屋都得到同一个数；再进一步，可以让预测随面积改变。相应推导见附录 A。

附录 C
补充数据与实验图

四份数据分别用于房价、收入、得分和成绩预测。表中列出文件规模和观测单位。Adult 数量包

数据	行数	列数	观测单位	默认目标
房价	1,460	81	一条房屋交易记录	成交价
Adult	48,842	15	一条人口特征记录	年收入是否超过 5 万美元
NBA	12,844	22	一条姓名与赛季表现记录	场均得分
学生成绩	1,000	8	一条课程样本记录	数学成绩

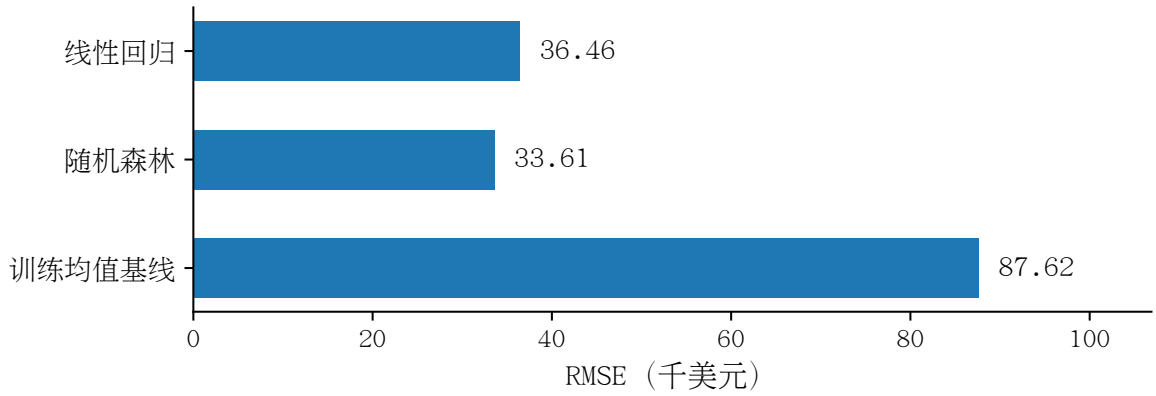
含原始训练和测试文件，NBA 列数包含导出的行索引。四份表分别分析。数据来源见 Kaggle [3]、Becker and Kohavi [4]、justinas [5] 和 spscientist [6]。

计算记录：tables/data_profile.csv；data/manifest.json

十二个配置在模型拟合前写入本地协议。八个主配置对应四份数据各两个算法，另外四个配置改变房价与 NBA 的划分方式。各配置固定超参数和随机种子，保留大误差记录。输入特征和样本划分见正文表 V。

A. 房价预测

房价主配置的验证误差见图 C.1。相同的六个输入变量下，线性回归的 R^2 为 0.8267，随机森林为 0.8527。房价未取对数，四条居住面积超过 4,000 平方英尺的记录保留，极端误差也计入 RMSE。

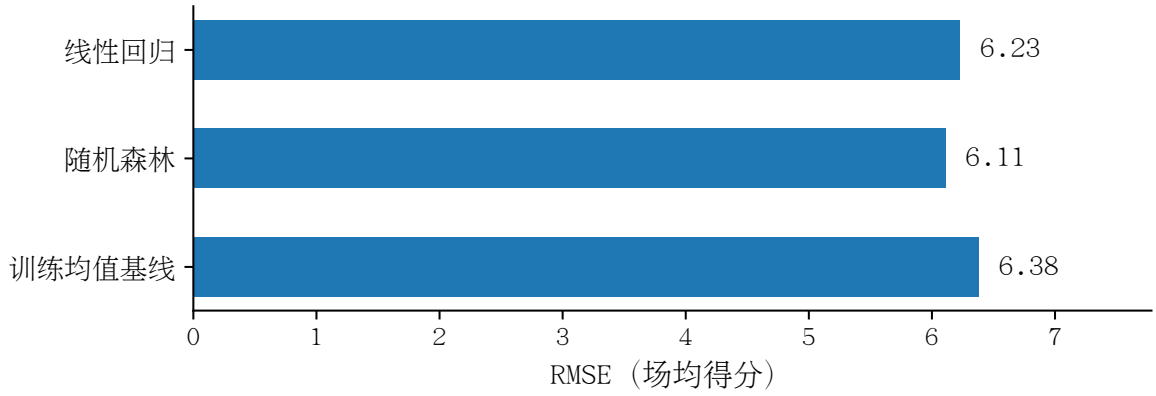


训练 1,168；验证 292。固定划分，无置信区间。

图 C.1 房价主配置的验证误差。横轴为千美元，数值越小越好。

B. 球员得分

NBA 的跨赛季验证误差见图 C.2。验证数据出现六个训练时未见的选秀年份类别，编码为全零，并记录提示。模型没有学习过这些类别的独立系数。按姓名分组与按赛季留出的结果见正文表 IV。

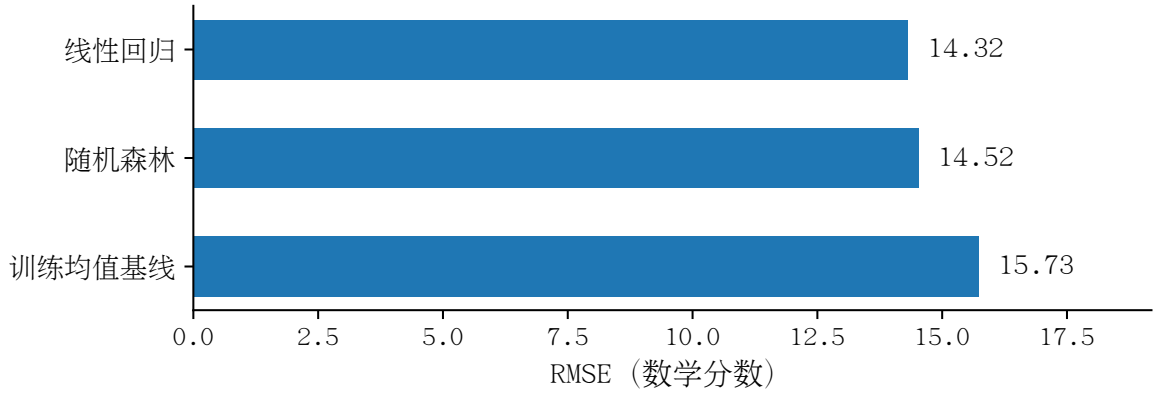


训练 9,561；验证 3,283。固定划分，无置信区间。

图 C.2 NBA 后六个赛季共 3,283 条记录的验证误差。单位为场均得分。

C. 学生成绩

学生数学成绩的验证误差见图 C.3。线性回归和森林的 MAE 分别为 11.453 与 11.502 分。两者使用相同的四个考前背景字段。



训练 800；验证 200。固定划分，无置信区间。

图 C.3 使用四个背景字段预测数学成绩，验证样本为 200 条。同期阅读、写作分数未作为输入。

收入分类验证集的正类比例约为 24.08%。训练正类比例作为常数概率时，Brier 分数为 0.1828；两个模型的结果见正文表 III。误报和漏报的用途及成本影响模型选择，本次比较固定使用 0.5 阈值。

十二个配置的全部数值保存在原 CSV 中，包括准确率、平衡准确率、平均精确率和改变划分方式后的结果。本文使用可查看、可重复计算的验证样本，最终盲测尚未开展。

计算记录：tables/model_comparison.csv；tables/metric_reconciliation.csv

附录 D
实现、数据与运行记录

A. 程序实现与操作

用一个完整问题串联实现：选房价，输入“用整体质量和居住面积预测成交价，先用线性回归”。检索器查找这几个字段和训练方法说明；DeepSeek API 生成包含目标、特征、划分与算法的分析方案；用户确认后，执行器拟合预处理与回归，再保存验证预测。请求使用 JSON 输出格式，并附带

文件	作用
tablelab/catalog.py	载入数据与字段说明，检查文件指纹，提供目标和变量信息。
tablelab/retrieval.py	建立字符 TF–IDF 索引，对当前问题返回相关说明。
tablelab/cloud/deepseek_online.py	组织 DeepSeek 请求，校验返回的 JSON 分析参数。
tablelab/cloud/deepseek_transport.py	通过 HTTPS 调用 DeepSeek API，解析响应与错误。
tablelab/contracts.py	规定参数结构及允许的操作，检查字段、算法与数量。
tablelab/engine.py	筛选、统计、划分、预处理、拟合、评估和预测。
tablelab/plotting.py	用实际结果生成 PDF 图。

本地方案的 JSON Schema；返回值还须通过本地参数校验。例如算法必须填已实现名称，数值筛选符号必须来自固定集合；对于“低价房”这样未给阈值的提问，仍需要澄清具体含义。格式通过检查后，也应核对语义是否符合原问题。

用户接着说“改成随机森林”，模型可以读取上一轮方案，将算法改为森林，并保留已经确定的目标和特征。重新执行时产生新的运行编号，重新拟合模型，保存新的验证预测。若说“只看 2000 年以后建成的房屋”，还需要修改筛选条件，并在筛选样本上重新划分和训练。

改变样本后，前后两组误差的评价对象也变了。界面应同时显示这次的筛选条件和训练、验证样本数，便于区分“算法变了”和“被预测的房屋变了”。用户可以修改这些条件，再检查新的计算结果。

先问 CollgCr 的平均成交价，核对参与计算的 150 条记录。随后用面积和质量建立线性回归，观察训练与验证数量、均值基线和误差；再改用随机森林，比较同一批验证记录。最后输入一套房屋的字段值，查看预测以及是否存在未见类别或超出训练范围的数值。

切换到 Adult 时，先比较教育组的高收入样本比例，再建立逻辑回归，解释一条概率怎样经过 0.5 阈值变成类别。NBA 可以比较后续赛季留出与姓名分组；学生任务可以比较考前信息与明确标注的同期估计问题。这些步骤是现场演示的操作安排。

每轮保存 plan.json 和 evidence.json，分别记录分析参数与检索片段；provenance.json 记录数据、代码和环境信息；统计值写入 result.json 与 CSV。训练任务还保存 split.csv、validation_predictions.csv、预处理参数、系数或置换重要性，以及 PDF 诊断图。

这些文件可以回答三类具体追问：这次选了哪些记录，程序怎样变换变量，预测值如何得到。reproduce.py 根据保存方案重算，executor_source.py 保留当时的执行代码。复现需匹配数据和依赖版本；单条预测依赖当前会话模型，服务重启后须先按训练方案重新拟合。

讲解计算脚本 tools/teaching_calculations.py 从上传数据重算社区均价和三条记录的直线，用保存的参数重建房价和 Adult 预测，并用数值差分检查逻辑回归梯度与 Hessian。十二个基准模型沿用已保存的结果，讲解计算的输出保存在单独目录。

B. 数据处理记录

上传的 Adult、NBA、学生 ZIP 及其内部文件哈希与下载清单一致。单独上传的房价 CSV 与 house-prices.zip 中的 CSV 逐字节相同。哈希用于识别文件版本。房价副本的下载出处及其与 Kaggle 官方副本的一致性待核实。原 ZIP、解压原件、处理副本分开保存，处理副本新增稳定行号。

房价有 6,965 个空白单元格，全部 1,460 行均至少含一个空白；Adult 两个文件合计有 6,465 个缺失单元格；NBA 与学生表未发现空白。原始行全部保留，没有全表删缺失、自动去重或分位数截尾。训练时只对所选特征拟合插补规则。

房价 MasVnrType 有 864 个字面值 None 与 8 个空白，NBA 的 college 有 1,854 个字面值 None。处理时保留这些类别字符串。房价 LotFrontage 缺失 259 条；地下室质量的 37 个空白均对应地下室面积为零，壁炉质量的 690 个空白均对应无壁炉，车库类型的 81 个空白均对应车位数为零，泳池质量的 1,453 个空白均对应泳池面积为零。这些对应关系提示部分空白可能表示没有设施；缺少上传副本的原始字段说明，项目没有据此改写原值。

房价 Id 为 524 的记录中，改建年份 2008 晚于出售年份 2007。程序标记并保留该记录，主模型未使用改建年份。四条居住面积超过 4,000 的记录也保留。相关原值和定位行号见 tables/row_flags.csv。

计算记录：tables/input_integrity.csv；tables/column_quality.csv；tables/house_missing_semantics.csv

adult.data 有 32,561 条，adult.test 有 16,281 条。原训练文件的全字段重复额外记录为 24 条，按 14 个原始非目标字段比较时为 25 条。原表缺少可靠的个人标识，相同字段可能来自重复录入，也可能属于不同个人。记录全部保留，划分时按全部原始预测字段的 SHA-256 指纹分组，相同字段的记录放在同一侧。

原训练、测试文件共有 26 个非目标字段指纹。原始测试文件已参与内容核查，没有用于模型训练和性能计算。以后若使用它评价模型，应事先规定重合指纹的处理方式。当前均值、比例和模型拟合都未使用 fnlwgt 加权。数据记录的是 1994 年相关人口普查样本的收入类别 [4]。

上传表有 27 个赛季，从 1996–97 到 2022–23；共有 2,551 个不同姓名字符串。下列四组姓名与赛季键各有两条记录，年龄或身高不同：Marcus Williams 的 2007–08、2008–09，Chris Johnson 的 2012–13，以及 Tony Mitchell 的 2013–14。缺少稳定球员 ID，八条记录均保留，未按姓名与赛季强行合并。姓名分组实验将相同姓名放在同组，没有完成真实身份消歧。

ts_pct 有 15 条大于 1。真实投篮效率的分母是加权出手次数，不是普通二项试验总次数 [17]。项目没有把该字段截断到 0–1；由于缺少对应的逐条出手次数，未对这些高值重新计算。基准特征未使用该字段。

数学、阅读、写作均在 0–100 分内，没有空白或全字段重复，均值分别为 66.089、69.169 和 68.054。源站致谢链接指向 generated_data/exams，原核查记录中的许可为 Unknown；本项目未取得生成脚本或真实抽样证明。本文将其作为课程样本分析，并保留源站记录 [6]。

C. 软件参数与统计约定

项目	当前实现
筛选与分组	最多 8 个 AND 条件、2 个分组字段；展示前若干行不改变计算样本。
统计	计数、均值、中位数、和、极值、标准差；两数值变量的 Pearson 相关；直方图、散点图、分组柱形图。
分母	分别记录组内行数 n_rows 和非缺失数 n_valid；全缺失组的和返回缺失。
训练规模	每次一个目标、最多 30 个特征；有效目标 100 至 100,000 条，划分后训练至少 60、验证至少 20 条。
预处理	数值中位数插补、训练均值和标准差缩放；分类单独缺失类、独热编码，最多 30 个编码类别并保留参考类。
未见类别	编为全零并提示；训练中全缺失的特征报错。
逻辑回归	$C = 1$，lbfgs，最多 1,500 次迭代，阈值 0.5，无额外概率校准。
森林	120 棵树，深度 12，叶节点最少 5 条，种子 42，单线程；置换重要性重复 3 次。
会话预测	最多保留四个表格模型；重启后重新拟合，不能继续使用已失效的模型编号。

达到条数上限时，程序报错，不自动抽取一部分样本；缺失目标只在本次拟合中排除，不改写原文件。没有实现的算法、模型未收敛、非法特征和样本不足都返回具体原因。线性模型不输出 p 值，森林不输出预测区间。

Pearson 相关使用两列同时非缺失的记录。令这些记录的集合为 A，其均值为 $\bar{x}_A, \bar{y}_A$，则

$$r = \frac{\sum_{i \in A}(x_i - \bar{x}_A)(y_i - \bar{y}_A)}{\sqrt{\sum_{i \in A}(x_i - \bar{x}_A)^2 \sum_{i \in A}(y_i - \bar{y}_A)^2}}.$$

分子是共同变化，分母用各自波动进行标准化。项目至少要求三条成对有效记录；常数列无法得到有定义的相关系数。相关操作不进行因果识别或显著性检验。

D. 运行与检查记录

四份表各有两个主要模型。房价和 NBA 各增加两个改变样本划分的模型，共 12 个固定配置。项目保存了每条验证记录的行号、实际值和预测值。原实验独立复算了 58 项指标。表 II 第一行另取自两个已完成的演示模型，不计入这 12 个固定配置。

从保存的逐行预测可以复算连续目标的 MAE、RMSE 和 R^2，并从收入分类概率复算 AUC、F_1、Brier 分数和对数损失。每次都按行号核对预测记录与验证样本。复算直接使用已保存的预测。附带的 `check_results.py` 读取原工程，输出相应数值。

DeepSeek 联网适配版的检查记录另见 codes/verification/deepseek/scope.txt：135 项测试通过，其中 26 项为新增联网适配测试；测试使用占位密钥和模拟 API 回复，没有调用付费服务。这些检查验证请求组织、错误处理和本地计算流程，不能据此报告真实 API 的方案生成准确率。

旧环境的 HTTP 状态接口可达，Chromium 打开页面却返回 ERR_BLOCKED_BY_ADMINISTRATOR，因此浏览器交互未验收。旧版全部运行记录随包保留。0.3 版另外复跑了 100 项组件测试，全部通过；35 项实际数据接口检查仍引用旧版记录，十二个模型配置没有重新拟合。

十二个配置的预处理参数来自各自训练子集；独立复算先按稳定行号对齐实际值和预测值，再重算指标。开发时出现过预测顺序与划分表顺序不一致，已通过行号对齐修正复算程序，原预测值未改。失败尝试保留在开发记录中。

记录	实际完成内容
0.2 数据核查	四份上传数据、缺失、重复、字段类型、文件一致性与划分问题。
0.2 固定模型	12 个配置；保存逐行验证预测；58 项指标独立复算一致。
0.2 组件检查	100 项通过，使用明确标注的合成夹具；模拟模型只检查消息协议。
0.2 实际数据接口	35 项通过，使用人工 JSON 参数；覆盖统计、训练、预测、PDF 及结果下载。
0.2 检索检查	16 道固定题前六条命中，MRR 为 0.96875；多数包含原字段名。
0.3 讲解计算	实算 CollgCr 均值和三条记录的 OLS；重建 292 条房价预测、6,512 条 Adult 概率；检查梯度与 Hessian。
仍需目标电脑实测	DeepSeek API 方案生成质量、浏览器完整交互、Mac 响应时间与峰值内存。

路径	内容
tables/model_comparison.csv	十二个模型配置的全部指标。
tables/metric_reconciliation.csv	从验证预测独立复算的 58 项结果。
tables/teaching/	均值样本、三条记录的 OLS、系数乘特征的逐项贡献。
artifacts/benchmarks/	旧版模型方案、划分、预测、系数、参数和执行代码。
artifacts/teaching/	本次社区均值计算的完整输出。
verification/editorial/	本次讲解计算、数学核对、文档编译与检查记录。

数学核对没有重新估计旧版基准模型。房价预测重建最大绝对差为 5.82×10^{-11} 美元，Adult 概率最大绝对差为 3.33×10^{-16}；这些数值反映浮点运算顺序差异。数值差分检查使用四条确定性代数输入，梯度和 Hessian 的最大误差分别为 1.08×10^{-11} 与 6.23×10^{-12}。

E. 自由中文问答的后续评价

现有 16 道固定题评价的是字段检索排名，其中 15 道含英文字段名。DeepSeek 联网适配测试使用模拟回复，尚未评价真实 API 的方案生成质量。后续将另设不含原始字段名的中文问题，覆盖四份数据的统计、预测与追问任务，保存原始问题、检索说明和 API 返回的原始方案。人工逐项核对数据集、目标与特征、筛选条件和算法，并记录执行结果及所需修改，分别统计原始方案与人工修正后方案的正确情况。该安排用于区分检索、方案生成与计算执行三个环节的错误。

F. 在 *Mac* 上准备与运行

工程内已有四份处理数据。当前演示入口为项目根目录的 TableLab-DeepSeek.command。双击该文件，或在终端进入项目目录运行：

```
bash TableLab-DeepSeek.command
```

启动器准备 Python 环境并启动本机网页。首次按终端提示隐藏输入 DeepSeek API Key，密钥默认存入当前用户的 Mac 钥匙串。浏览器打开 http://127.0.0.1:8765，演示结束在服务终端按 Control-C。

当前 API 客户端调用 https://api.deepseek.com/chat/completions，模型参数以 tablelab/cloud/deepseek_transport.py 中的配置为准。请求发送问题、字段名与类型、字段和方法说明及必要的上一轮

方案；不整表上传原始 CSV。用户在问题或筛选条件中输入的内容也会随请求发送。返回值通过本地格式和字段检查后，交由用户核对，再由本机执行器计算。统计、模型训练与结果文件均在本机完成。生成新方案需要联网，API 用量由服务提供方计费。

打开网页，选「房价」，输入「CollgCr 社区房屋的平均成交价是多少?」。点击「检索并生成方案」，核对社区条件与统计方法，查看「检索依据」里的字段说明。点击「校验并执行」，对照 150 条有效记录和 197,965.77 美元的均价，再打开本轮的 CSV 与执行器源代码。

清空上下文后，要求用全部房屋记录、居住面积和整体质量做线性回归。确认方案里没有社区筛选，运行后让听众改一个条件。只改算法时，两次训练应使用同一批房屋。分别查看运行编号与验证误差。

远程汇报时共享本机浏览器窗口并保持网络连接。服务不可用时查看网页错误提示；随包的 HTML 回放只能查看保存的例题，不能生成新方案。

G. 重建文档

图形使用本目录的 PDF。论文使用 XeLaTeX、BibTeX 和 natbib，在本目录运行 bashbuild_paper.sh，生成包含附录的 paper.pdf。

参考文献

[1] J. Herzig, P. K. Nowak, T. Müller, F. Piccinno, and J. M. Eisenschlos, “TaPas: Weakly supervised table parsing via pre-training,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020, pp. 4320–4333.

[2] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, “Retrieval-augmented generation for knowledge-intensive NLP tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474.

[3] Kaggle, “House prices: Advanced regression techniques,” Kaggle Competition, n.d.

[4] B. Becker and R. Kohavi, “Adult,” UCI Machine Learning Repository, 1996.

[5] justinas, “NBA players,” Kaggle Datasets, n.d.

[6] spscientist, “Students performance in exams,” Kaggle Datasets, n.d.

[7] scikit-learn developers, “Nested versus non-nested cross-validation,” n.d., 官方文档；访问日期：2026-11-01. [Online]. Available: https://scikit-learn.org/1.8/auto_examples/model_selection/plot_nested_cross_validation_iris.html

[8] Optuna developers, “Samplers,” n.d., 官方文档；访问日期：2026-11-01. [Online]. Available: https://optuna.readthedocs.io/en/stable/reference/samplers/index.html

[9] SHAP developers, “Treeexplainer,” n.d., 官方文档；访问日期：2026-11-01. [Online]. Available: https://shap.readthedocs.io/en/stable/generated/shap.TreeExplainer.html

[10] scikit-learn developers, “Linear models,” scikit-learn 1.8 documentation, n.d.

[11] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, pp. 5–32, 2001.

[12] scikit-learn developers, “Common pitfalls and recommended practices,” n.d., 官方文档；访问日期：2026-10-30. [Online]. Available: https://scikit-learn.org/stable/common_pitfalls.html

[13] ——, “Decision trees: Mathematical formulation,” n.d., scikit-learn 1.8 文档；访问日期：2026-10-31. [Online]. Available: https://scikit-learn.org/1.8/modules/tree.html

[14] ——, “RandomForestClassifier,” n.d., scikit-learn 1.8 文档；访问日期：2026-10-31. [Online]. Available: https://scikit-learn.org/1.8/modules/generated/sklearn.ensemble.RandomForestClassifier.html

[15] ——, “RandomForestRegressor,” n.d., scikit-learn 1.8 文档；访问日期：2026-10-31. [Online]. Available: https://scikit-learn.org/1.8/modules/generated/sklearn.ensemble.RandomForestRegressor.html

[16] ——, “TfidfTransformer,” n.d., scikit-learn 1.8 文档；访问日期：2026-10-31. [Online]. Available: https://scikit-learn.org/1.8/modules/generated/sklearn.feature_extraction.text.TfidfTransformer.html

[17] National Basketball Association, “Nba stats glossary: True shooting percentage,” n.d., 官方统计定义；访问日期：2026-10-30；未用该页面认证上传记录. [Online]. Available: https://www.nba.com/stats/help/glossary