TableLab：基于本地字段检索的中文表格问答与预测

天津大学机器学习与人工智能课程报告

郑嘉诚

马寅初经济学院　应用经济学
学号：2026209004

2026 年 11 月 1 日

字段检索和模型预测分别检查

用户问“CollgCr 社区的平均成交价是多少”，程序需要先选对社区与成交价两列，再筛选记录并求均值。

本文分别检查两件事：检索器把所需字段排在什么位置；使用相同样本时，输入变量和算法怎样影响预测误差。

选错列后，算术结果仍可能正确。因此字段检索和模型预测分别报告。

TaPas 从表中选择单元格并聚合 [1]；TableLab 检索字段说明，再读取原表计算 [2]。

四份数据与预测输入

数据	预测目标	输入变量
房价，1,460 条	成交价	整体质量、居住面积、建成年份、地下室面积、车位数、社区
Adult，48,842 条	年收入是否超过 5 万美元	年龄、教育编码、周工时、用工类别、职业、婚姻状况
NBA，12,844 条	场均得分	年龄、身高、体重、选秀年份类别
学生，1,000 条	数学成绩	性别、父母教育程度、午餐类别、是否完成备考课程

四份表分别分析。学生成绩按考前预测处理，输入中不含同期阅读和写作成绩。

Adult 行数包含独立测试文件的 16,281 条记录，该文件未参加模型拟合或验证。数据来源见 [3–6]。

原单次划分复核的样本

主题	训练	验证	划分
房价	1,168	292	固定随机 80/20。
Adult	26,049	6,512	在原训练文件内按收入分层，相同预测字段的记录放在同组。
NBA	9,561	3,283	后六个完整赛季留出。
学生	800	200	固定随机 80/20。

同一任务的两个算法使用相同记录。Adult 只采用五折分组器的第一个划分；学生输入不包含同期其他考试分数。

主实验使用四份数据各两个模型：房价与 NBA 另有四个改变划分方式的配置。

先检索字段说明，再计算均价

收到的问题	“CollgCr 社区的平均成交价是多少？”
本地检索	查找社区、成交价的字段说明与均值计算说明。
方案生成	DeepSeek API 返回字段名、筛选条件和统计方法。
程序执行	读取完整筛选样本，计算均值，保存结果。

本地字段检索为 DeepSeek 提供说明；返回的 JSON 方案经核对后，由本机读取原表计算成交均价。

检索增强生成的基本思路见 Lewis et al. [2]。本项目检索本地字段说明。

计算 CollgCr 社区的平均成交价

表格中的两列：

`Neighborhood`：社区类别。

`SalePrice`：成交价。

选出社区等于 CollgCr、成交价有记录的行。

成交记录的计算结果为

$$n = 150, \quad \sum y_i = 29\,694\,866.$$

$$\bar{y} = \frac{29\,694\,866}{150}$$

197,965.77 美元

计算记录：`tables/teaching/collgcr_members.csv`。完整房价表有 1,460 条记录。

把问题写成计算参数

```
{
  "dataset": "house",
  "operation": "aggregate",
  "columns": ["SalePrice"],
  "filters": [
    {"column": "Neighborhood", "op": "eq", "value": "CollgCr"}
  ],
  "group_by": [],
  "metric": "mean"
}
```

每个参数都能与原问题核对：哪个表、哪一列、筛选谁、算什么。

本例使用人工给定并已执行的参数。

把字符片段转成 TF–IDF 权重

“平均成交价”拆成长度为 2、3、4 的连续字符片段。设片段 t 在说明 d 中出现 c_{td} 次。

$$\mathrm{tf}(t,d) = 1 + \log c_{td} \quad (c_{td} > 0),$$

$$\mathrm{idf}(t) = 1 + \log \frac{N+1}{\mathrm{df}(t)+1}.$$

TF 对重复计数取对数；IDF 增加较少见片段的权重。权重为二者之积。

当前程序使用字符 2–4 元组、平滑 IDF 与次线性 TF，见 scikit-learn developers [7]。

用余弦相似度排序字段说明

权重向量先归一化，查询与文档的点积就是余弦相似度：

$$s(q,d)=\frac{\mathbf{w}_q^{\top}\mathbf{w}_d}{\|\mathbf{w}_q\|_2\|\mathbf{w}_d\|_2}.$$

开头均价问题的实际检索	分数
`Neighborhood` 字段说明	0.176436
`SalePrice` 字段说明	0.070664
房价数据说明	0.058073

房价索引共 90 份文档，最多返回六条正相似度结果。分数衡量问题与说明之间的词面匹配。

16 道固定检索题的目标都在前六位

四份数据各有 4 道题，每题指定一条目标字段或方法说明。

目标说明的排名	题数
第一位	15
第二位	1
前六位命中	16

$$\mathrm{MRR} = \frac{15 + 1/2}{16} = 0.96875.$$

15 道题写出了目标英文字段名。排在第二位的题目询问 `player_name` 是否是唯一身份，姓名说明排在身高说明之后。

预测模型使用相同的输入和划分

模型	预测方法
均值基线	连续目标都预测为训练均值，用作误差参照。
线性回归	用处理后的特征拟合 $\hat{y}_i = \beta_0 + z_i^{\mathsf{T}}\beta$。
逻辑回归	用 $p_i = 1/(1+e^{-\eta_i})$ 预测高收入概率，阈值为 0.5。
随机森林	平均 120 棵树的预测；最大深度 12，叶节点至少 5 条记录。

先划分样本，再用训练集确定插补、缩放和类别编码。实验固定超参数。

逻辑回归使用 $C = 1$ 和 L-BFGS，最多迭代 1,500 次。模型定义见 [8, 9]，详细推导放在补充页。

用 MAE、RMSE 和 R^2 评价预测

记验证残差 $e_i = y_i - \hat{y}_i$，验证数为 n_V。

$$\mathrm{MAE} = \frac{1}{n_V}\sum_i |e_i|, \qquad \mathrm{RMSE} = \sqrt{\frac{1}{n_V}\sum_i e_i^2}.$$

MAE 平均绝对差；RMSE 对大误差更敏感，二者保留目标原单位。

$$R^2 = 1 - \frac{\sum_i e_i^2}{\sum_i (y_i - \bar{y}_V)^2}.$$

R^2 分母使用验证均值衡量波动。可执行的常数预测仍使用训练均值。

房价误差同时取决于输入变量和算法

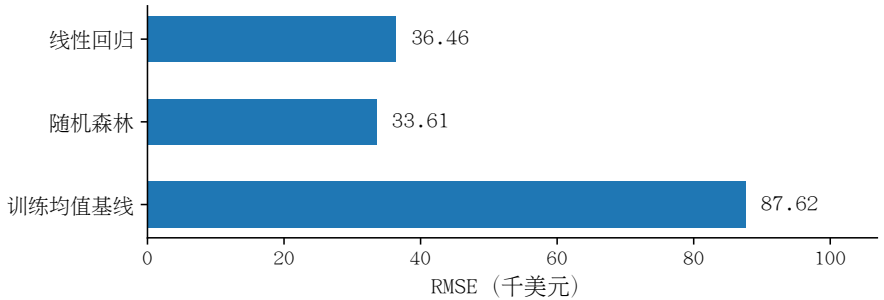
输入变量	线性回归 RMSE	森林 RMSE
面积、整体质量	44,159.60	39,205.81
再加建成年份、地下室面积、车位数和社区	36,461.68	33,611.50

两组模型使用相同的 1,168 条训练记录和 292 条验证记录。加入四个变量后，两种算法的误差都下降。

六变量线性回归比两变量森林的 RMSE 低约 2,744 美元。

单位为美元。两字段结果来自演示计算，六字段结果来自固定基准实验。四个变量同时加入，表中反映其共同变化。

房价预测中森林的误差较小

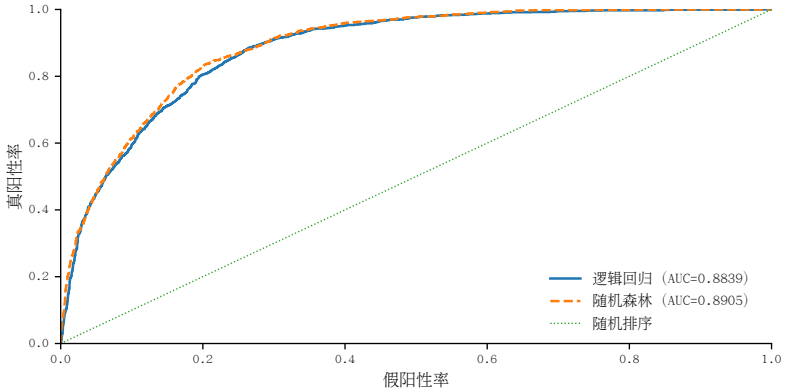


训练 1,168；验证 292。固定划分，无置信区间。

线性回归 $R^2 = 0.8267$，森林 $R^2 = 0.8527$。六个输入变量相同；线性回归与森林的 MAE 分别为 22,339.33 和 20,019.09 美元。

训练 1,168，验证 292；误差来自同一固定划分。

收入分类的 ROC 曲线



曲线比较不同阈值下的识别与误报比例。森林 AUC 为 0.8905，逻辑回归为 0.8839。

验证记录共 6,512 条，含 1,568 个正例。AUC 比较正负记录的排序，并列分数计作一半。

收入分类中森林的 AUC 更高、F1 更低

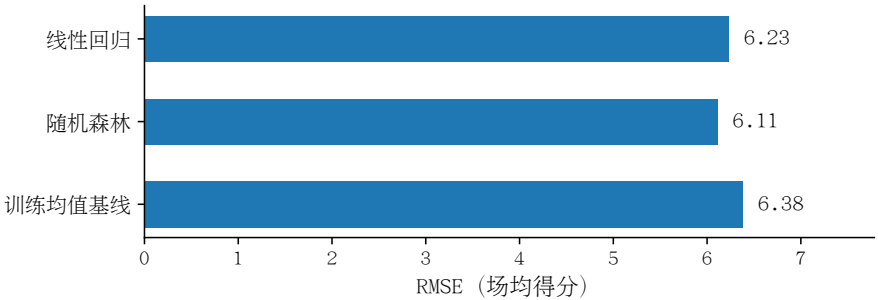
模型	AUC	F1	Brier	对数损失
逻辑回归	0.8839	0.6026	0.1150	0.3559
随机森林	0.8905	0.5916	0.1125	0.3484

森林识别 791 个正例，误报 315 个，漏报 777 个；逻辑回归分别为 849、401 和 719 个。

AUC 比较正负记录的整体排序；F1 取决于阈值后的分类。森林减少误报，同时漏掉更多正例。

阈值均为 0.5；原始 adult.test 未参加性能计算。

用身体属性和选秀年份预测得分

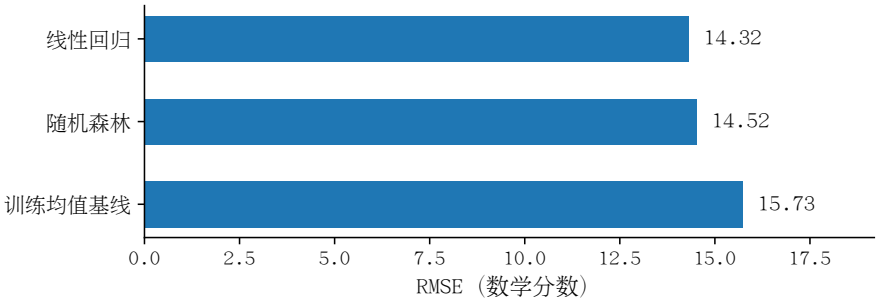


训练 9,561；验证 3,283。固定划分，无置信区间。

输入为年龄、身高、体重和选秀年份。线性回归 $R^2 = 0.0390$，森林为 0.0753。

验证为 2017–18 至 2022–23。森林 RMSE 为 6.112 分，训练均值基线为 6.380 分，相差约 0.27 分。

学生成绩预测中线性回归的误差略低



训练 800；验证 200。固定划分，无置信区间。

输入性别、父母教育、午餐类别和备考课程。线性回归 $R^2 = 0.1573$，森林为 0.1331。

训练 800、验证 200。线性回归 RMSE 比森林低 0.204 分；备考课程系数描述样本关联。

换一种划分，评价的问题也变了

划分	线性回归 RMSE	森林 RMSE
房价：2010 年 175 条记录留出	35,008.88	30,310.72
NBA：姓名分组，验证 2,472 条	5.835	6.016

房价按年份留出，NBA 按姓名分组。每一行使用相同验证记录比较两个算法，误差按各自目标的单位报告。

房价单位为美元；NBA 为场均得分。NBA 姓名分组的训练集为 10,372 条，验证集为 2,472 条；同名球员身份待核实。

四个任务都做多模型、调参与解释

比较常数、线性正则化、决策树、森林、Extra Trees、提升树与近邻，共九种预设方法。

森林与提升树分别增加网格、TPE 两条流程。每个任务共十三条比较流程，使用相同输入字段。

训练与验证曲线检查拟合差距；SHAP 解释字段贡献，删去特征组后重新调参检验替代信息。

此前为单次划分，森林用 120 棵树；此处为三折嵌套，预设森林用 64 棵树。样本也不同，两组数值不能当作调参前后的变化。

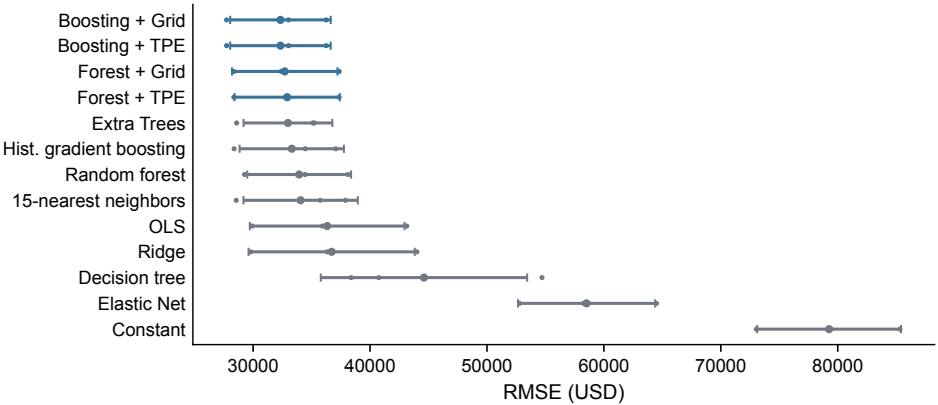
外层评价，内层选参数

任务	内外层划分约束
房价、学生	固定随机三折。
Adult	按原始非目标字段指纹分组并分层。
NBA	按完整赛季向前滚动，验证晚于训练。

外层三折，内层沿用同一分折规则再分三折；每次搜索十二组参数。插补、缩放和编码均在训练折内拟合。

两种搜索使用相同十二点离散域。主搜索共 1,728 次内层拟合，消融另行搜索。

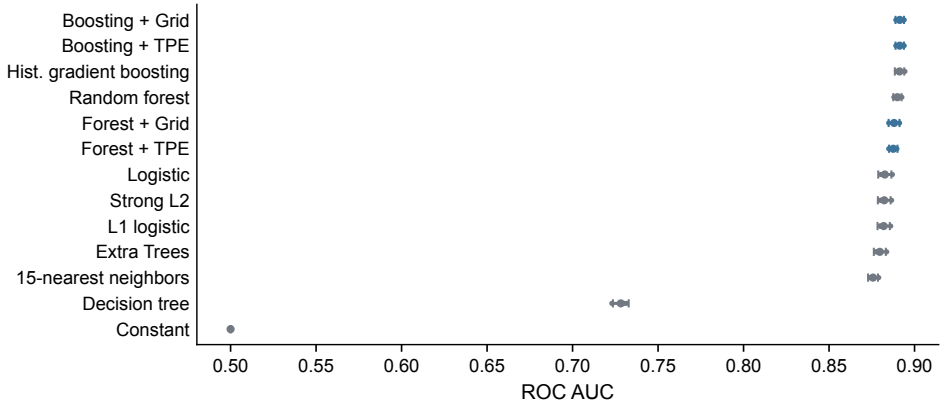
房价的多模型比较



提升树＋网格的三折平均 RMSE 为 32338.23。

点为各折，误差线为折间标准差；排序描述本次结果。

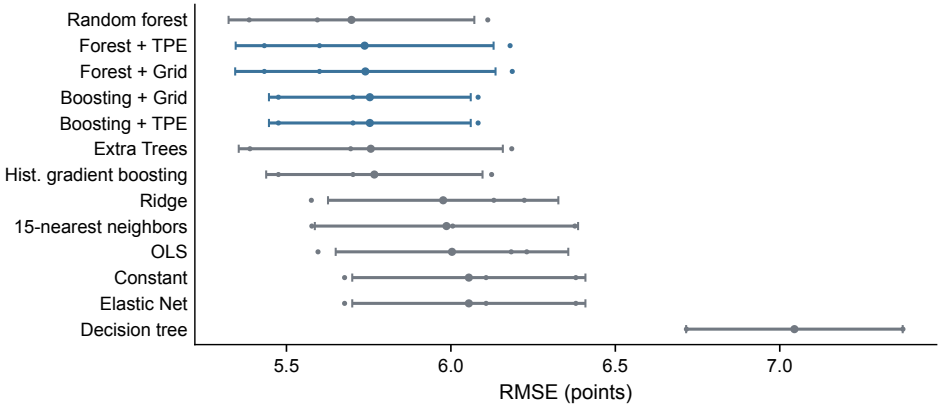
收入分类的多模型比较



提升树＋网格的三折平均 AUC 为 0.8913。

点为各折，误差线为折间标准差；排序描述本次结果。

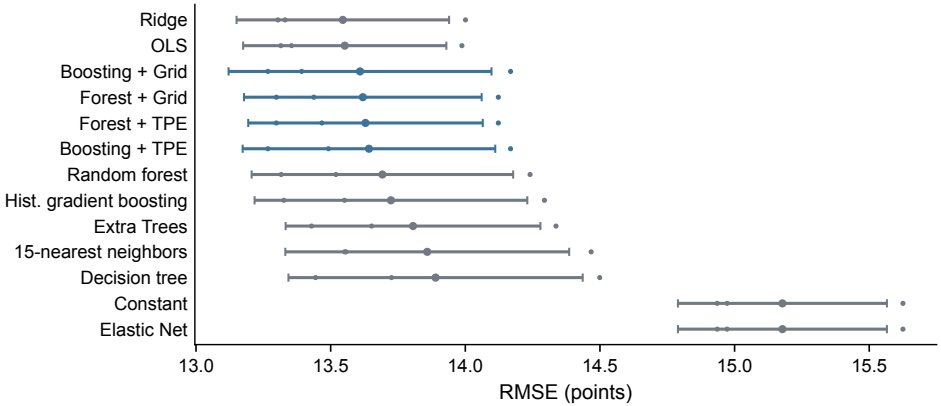
NBA 得分的多模型比较



随机森林的三折平均 RMSE 为 5.698。

点为各折，误差线为折间标准差；排序描述本次结果。Elastic Net 在三折中系数全为零，等于训练均值基线。

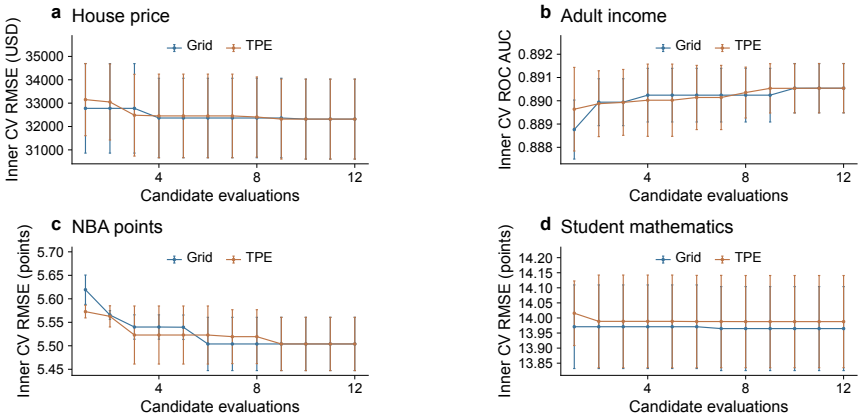
学生成绩的多模型比较



Ridge 的三折平均 RMSE 为 13.545。

点为各折，误差线为折间标准差；排序描述本次结果。Elastic Net 在三折中系数全为零，等于训练均值基线。

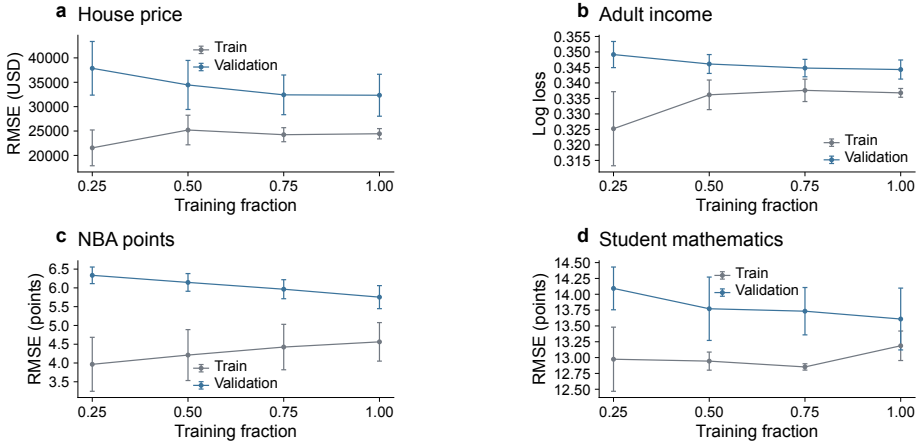
调参收益要在外层验证



外层变化（提升树）：房价 RMSE 降 966.57 美元，NBA 降 0.014 分；学生降 0.115 / 0.082 分，收入 AUC 增 0.0001。森林在收入和 NBA 上反而略差。

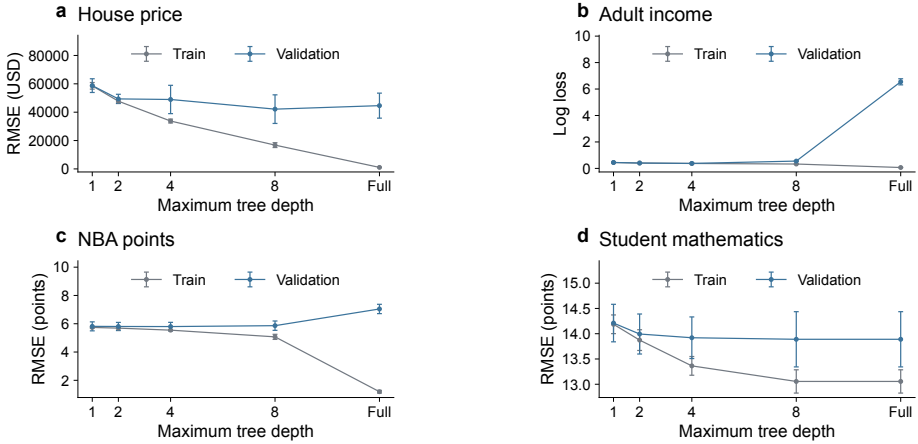
学生依次为网格、TPE。图为内层最优分数轨迹；外层变化在同折预设模型与调参模型间计算。

增加训练数据后，误差怎样变化



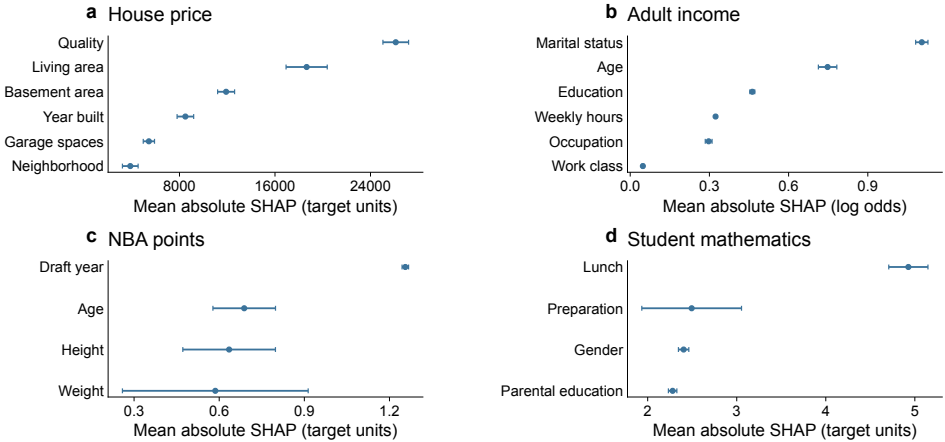
训练与验证均值及折间标准差。分类使用对数损失，回归使用 RMSE；各训练子样本重新拟合预处理。

树越深，训练误差越低吗



Full 为不限制深度。训练与验证差距支持诊断过拟合；两者都高还需检查输入信息是否充分。

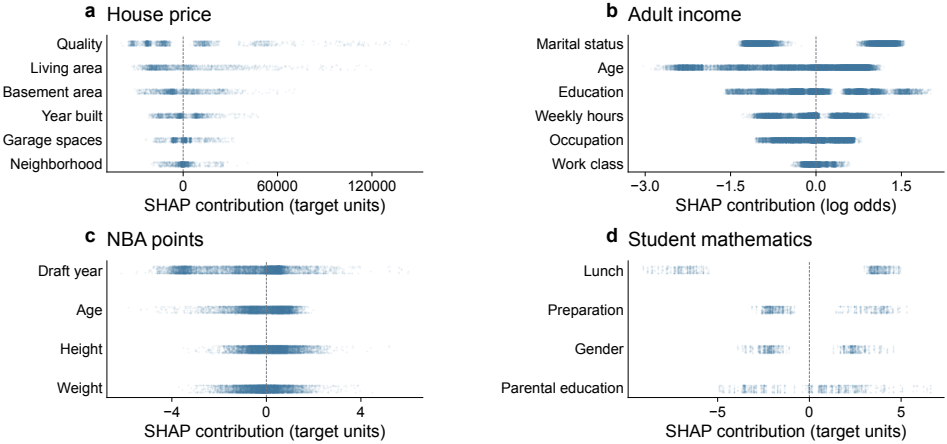
SHAP 描述模型使用了哪些字段



房价的 SHAP 以整体质量最高；删去面积组的损失却最大，RMSE 增加 7,000.18 美元。

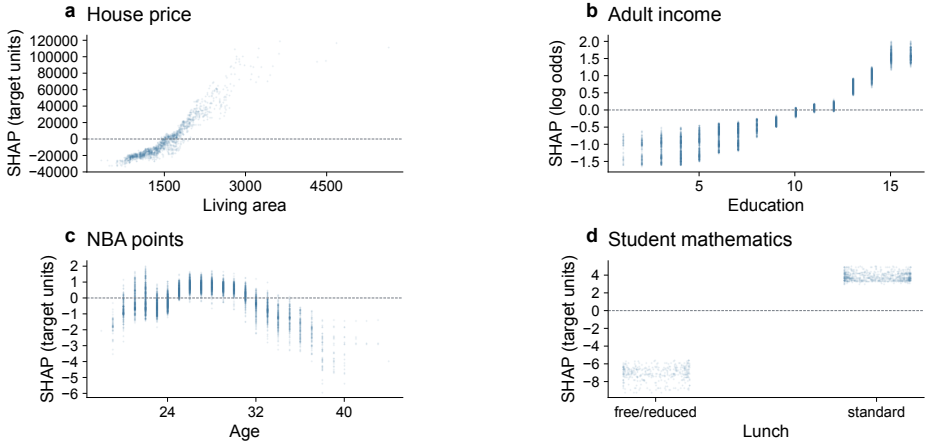
解释预先指定的网格调参提升树，使用全部外层验证记录。分类贡献在对数几率尺度上分解。

SHAP 贡献在样本间怎样分布



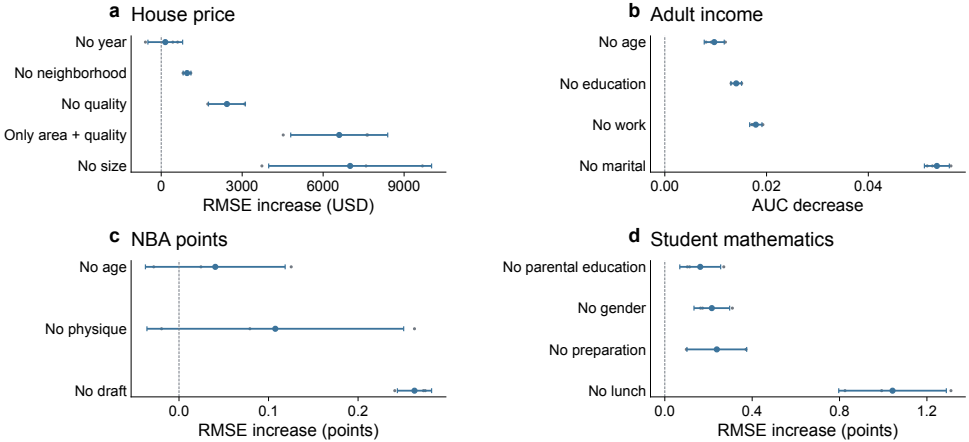
每点对应一条外层验证记录；横轴为原始字段贡献，纵向抖动仅用于显示重叠。

特征取值与模型贡献



各点是实际外层验证记录；点云描述模型内的预测关联。午餐为类别字段。

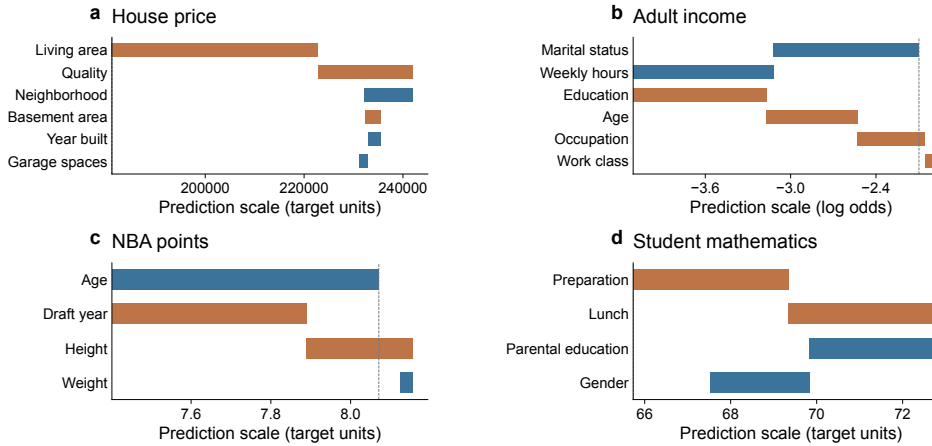
删除字段后，重新训练与调参



消融会重新训练，其余字段可以替代被删信息，因此它与 SHAP 贡献排名可以不同。

Only area + quality 仅保留地上居住面积与整体质量。正值表示性能损失，负值表示改善；各变体使用同折记录并重新调参。

查看一条代表性预测的贡献



每个任务选择绝对预测误差居中的记录。橙色提高预测、蓝色降低预测；贡献加和已逐条核对。

现场从一个问题继续追问

用户改变什么	程序重新做什么
“换一个社区求均价”	修改筛选条件，重算参与记录与均值。
“面积、质量预测房价”	划分数据，拟合预处理和线性回归。
“改用随机森林”	保留目标和特征，重新拟合并比较验证预测。
“只保留 2000 年后建成的房屋”	改变样本，重新划分和训练，显示新的样本数。

以上是演示步骤。每次运行保存新的方案、运行编号、代码和结果。

模型表现、解释和应用边界

房价的较小平均 RMSE 为 32,338.23 美元，来自提升树＋网格；收入分类中，提升树＋网格的 AUC 为 0.8913。NBA 得分由随机森林取得较小平均误差（5.698 分），学生成绩则是 Ridge（13.545 分）。

训练误差下降后，仍需看外层验证。调参收益与特征消融按同折比较；SHAP 说明预测贡献，解释因果效应还需要识别设计。

DeepSeek API 负责问题到方案，检索与数值训练在本机执行。

检索检查仅用 16 道固定题，其中 15 道含英文字段名；DeepSeek API 的方案生成质量尚未评价。

均值使用有效记录数作分母

$$S = \{i : \text{Neighborhood}_i = \text{CollgCr},\ y_i \text{ 有记录}\}, \qquad \bar{y}_S = \frac{\sum_{i \in S} y_i}{|S|}.$$

问题	参与计算的值	分母
CollgCr 的成交均价	社区内有成交价的记录	150
全表临街长度的均值	`LotFrontage` 非缺失记录	1,201

全表有 1,460 行，临街长度缺失 259 条。均值使用其余 1,201 条记录。

程序同时保存筛选后行数 `n_rows` 与当前字段有效数 `n_valid`。

用房屋属性预测成交价

均价只给出一个数。新房屋的面积、质量和社区不同，预测也可以随之改变。

$$\text{常数}c \quad \longrightarrow \quad b_0 + b_1 \text{面积} \quad \longrightarrow \quad \beta_0 + \sum_j \beta_j z_j.$$

先求最合适的常数，再求一条直线，最后加入多个特征。

训练均值使常数预测的平方误差最小

用同一个 c 预测训练样本，最小化平方误差：

$$L(c) = \sum_{i=1}^{n} (y_i - c)^2.$$

对 c 求导，令导数为零：

$$L'(c) = -2 \sum_{i} (y_i - c) = 0 \quad \Rightarrow \quad nc = \sum_{i} y_i.$$

所以 $\hat{c} = \bar{y}$。又有 $L''(c) = 2n > 0$，这是最小值。

验证时，每套房屋都用训练均价作为常数预测。

让预测随面积变化

$$\hat{y}_i = b_0 + b_1 x_i, \qquad L(b_0, b_1) = \sum_i (y_i - b_0 - b_1 x_i)^2.$$

x_i 为面积，y_i 为成交价。b_1 表示面积增加一单位时，拟合价格的变化。

先对截距求偏导：

$$\frac{\partial L}{\partial b_0} = -2 \sum_i (y_i - b_0 - b_1 x_i) = 0.$$

整理得 $\hat{b}_0 = \bar{y} - \hat{b}_1 \bar{x}$。因此直线经过 $(\bar{x}, \bar{y})$。

由一阶条件求出斜率

代入截距，残差变成 $(y_i - \bar{y}) - b_1(x_i - \bar{x})$。

$$\frac{\mathrm{d}L}{\mathrm{d}b_1} = -2\sum_i (x_i - \bar{x})\{(y_i - \bar{y}) - b_1(x_i - \bar{x})\} = 0.$$

把含 b_1 的项移到一侧：

$$\hat{b}_1 \sum_i (x_i - \bar{x})^2 = \sum_i (x_i - \bar{x})(y_i - \bar{y}).$$

$$\boxed{\hat{b}_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}}$$

面积有变化时分母为正。分子描述面积与价格如何共同偏离各自均值。

把三条原始记录代入算式

Id	面积	成交价
1	1,710	208,500
2	1,262	181,500
3	1,786	223,500

$\bar{x} = 1586$，$\bar{y} = 204500$。

面积单位为平方英尺，价格单位为美元。

去均值后：

$$x - \bar{x} = (124, -324, 200),$$

$$y - \bar{y} = (4000, -23000, 19000).$$

$$\hat{b}_1 = \frac{11\,748\,000}{160\,352} = 73.2638.$$

$\hat{b}_0 = 88\,303.58$。

三条记录用于讲解闭式解；正式评估使用完整数据的固定训练与验证划分。

正式模型先留出 292 套房屋

部分	条数	用途
训练	1,168	学习插补、缩放、编码和回归参数。
验证	292	沿用训练变换，比较预测与实际成交价。

随机种子固定为 42。线性回归和随机森林使用同一批训练、验证记录。

常数基线：每套验证房屋都预测为训练均价 181,441.54 美元。

先划分再拟合预处理，见 scikit-learn developers [10]。

数值变量：先插补，再标准化

训练非缺失值的中位数用于填补缺失，得到 $\tilde{x}_{ij}$。随后计算：

$$\mu_j = \frac{1}{n_T} \sum_{i \in \mathcal{T}} \tilde{x}_{ij}, \qquad s_j = \sqrt{\frac{1}{n_T} \sum_{i \in \mathcal{T}} (\tilde{x}_{ij} - \mu_j)^2}.$$

$$z_{ij} = \frac{\tilde{x}_{ij} - \mu_j}{s_j}.$$

$z_{ij} = 1$ 表示高于训练均值一个训练标准差。验证记录和新房屋使用同一组 μ_j, s_j。

当前 StandardScaler 使用分母 n_T；零方差采用缩放因子 1，全缺失特征报错。

用 0 和 1 表示社区类别

为每个非参考社区建立一个 $0/1$ 变量：

$$D_{i,\mathrm{CollgCr}} = \begin{cases} 1, & \text{房屋属于 CollgCr,} \\ 0, & \text{其他社区.} \end{cases}$$

社区指示变量之和恒为 1，因此有截距时保留一个参考社区。

房价主配置：5 个数值变量，25 个社区，参考社区 Blmngtn。

$$5 + 24 = 29 \text{ 个斜率参数，另加一个截距。}$$

遇到训练时未见的类别，编码为全零并提示；该类别没有被模型单独学习。

多元回归把所有预测写成 $X\beta$

$$X = \begin{pmatrix} 1 & z_{11} & \cdots & z_{1p} \\ 1 & z_{21} & \cdots & z_{2p} \\ \vdots & \vdots & & \vdots \\ 1 & z_{nT1} & \cdots & z_{nTp} \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}.$$

$$L = (\mathbf{y} - X\boldsymbol{\beta})^{\mathsf{T}}(\mathbf{y} - X\boldsymbol{\beta}) = \mathbf{y}^{\mathsf{T}}\mathbf{y} - 2\boldsymbol{\beta}^{\mathsf{T}}X^{\mathsf{T}}\mathbf{y} + \boldsymbol{\beta}^{\mathsf{T}}X^{\mathsf{T}}X\boldsymbol{\beta}.$$

第一列的 1 对应截距，每一行对应一套训练房屋。

令梯度为零，得到正规方程

$$\nabla L = -2X^{\mathsf{T}}\mathbf{y} + 2X^{\mathsf{T}}X\boldsymbol{\beta} = 0.$$

所以

$$X^{\mathsf{T}}X\hat{\boldsymbol{\beta}} = X^{\mathsf{T}}\mathbf{y}.$$

满列秩时：

$$\hat{\boldsymbol{\beta}} = (X^{\mathsf{T}}X)^{-1}X^{\mathsf{T}}\mathbf{y}.$$

实际程序使用数值最小二乘求解。特征精确共线时，系数可能不唯一。

实现对应 LinearRegression；数值算法说明见 scikit-learn developers [8]。

把面积系数换回原始单位

模型使用标准化面积，所以先换回原单位：

$$\beta_j z_j = \frac{\beta_j}{s_j}\tilde{x}_j - \frac{\beta_j \mu_j}{s_j}.$$

房价主配置的面积系数为 24,586.18，训练标准差为 524.2081 平方英尺。

$$\frac{24\,586.18}{524.2081} = 46.9016 \text{ 美元/平方英尺}.$$

其余输入相同，面积增加 100 平方英尺，模型预测增加约 4,690.16 美元。

这个价格差来自拟合关系。实际改造收益还取决于其他因素和成本。

把各项贡献相加，得到房价预测

项目	贡献（美元）	项目	贡献（美元）
截距	158,544.58	建成年份	$-2,148.44$
整体质量	$-1,910.59$	地下室面积	-56.05
居住面积	$-21,546.65$	车位数	$-10,010.56$
Sawyer 社区	19,112.54		

预测 141,984.82 美元；实际 154,500 美元；残差 12,515.18 美元。

记录 `house:00000892`。每项为编码值乘系数；展示数四舍五入。全部 292 条预测已从保存参数重建，最大差小于 6×10^{-11} 美元。

Adult 要预测一个概率

年收入超过 5 万美元记为 $y = 1$，其余记为 $y = 0$。目标是

$$p = P(y = 1 \mid \mathbf{z}).$$

令对数几率随特征线性变化：

$$\log \frac{p}{1-p} = \eta = \beta_0 + \mathbf{z}^{\mathsf{T}}\boldsymbol{\beta}.$$

$p = 0.8$ 的几率为 4；$p = 0.2$ 的几率为 $1/4$。

Adult 提供收入类别，没有具体工资金额；目标定义见 Becker and Kohavi [4]。

从对数几率解出 sigmoid

$$
\begin{aligned}
\log \frac{p}{1-p} &= \eta, \\
\frac{p}{1-p} &= e^{\eta}, \\
p &= e^{\eta}(1-p), \\
p(1+e^{\eta}) &= e^{\eta}.
\end{aligned}
$$

$$
\boxed{p = \frac{1}{1+e^{-\eta}}}
$$

$\eta = 0$ 时概率为 0.5；η 增大时概率接近 1。

用负对数似然拟合参数

单条记录的概率可统一写为 $p_i^{y_i}(1-p_i)^{1-y_i}$。

$$\mathcal{L} = \prod_{i \in \mathcal{T}} p_i^{y_i}(1-p_i)^{1-y_i}$$

取对数把乘积变成求和，再加负号：

$$\ell = -\sum_{i \in \mathcal{T}} \left[y_i \log p_i + (1-y_i) \log(1-p_i) \right].$$

实际为 1 却给出很小的 p_i，$-\log p_i$ 很大；实际为 0 却给出很大的 p_i，$-\log(1-p_i)$ 很大。

似然乘积采用模型中的条件独立假设。

用链式法则求梯度

先分别求导：

$$\frac{\mathrm{d}p_i}{\mathrm{d}\eta_i} = p_i(1-p_i), \qquad \frac{\partial \ell_i}{\partial p_i} = \frac{p_i - y_i}{p_i(1-p_i)}.$$

两项相乘：

$$\frac{\partial \ell_i}{\partial \eta_i} = p_i - y_i.$$

将截距并入 $\mathbf{x}_i$，有 $\eta_i = \mathbf{x}_i^{\mathsf{T}}\boldsymbol{\beta}$，所以

$$\nabla \ell = X^{\mathsf{T}}(\mathbf{p} - \mathbf{y}).$$

用 L2 惩罚约束系数

无样本权重时，scikit-learn 1.8 **的等价目标为**

$$J = \frac{1}{n_T}\sum_i \ell_i + \frac{1}{2Cn_T}\sum_{j=1}^{p}\beta_j^2, \qquad C = 1.$$

截距不受惩罚。令 $D = \mathrm{diag}(0, 1, \ldots, 1)$**：**

$$\nabla J = \frac{X^{\mathsf{T}}(\mathbf{p} - \mathbf{y})}{n_T} + \frac{D\boldsymbol{\beta}}{Cn_T}.$$

概率含有未知参数，需要迭代求解。实际使用 `lbfgs`**，迭代上限为** 1,500。

该目标是论文正文损失除以 n_T 后的形式，最优参数相同。参数定义见 scikit-learn developers [8]。Hessian 推导见补充页。

用 0.5 阈值把概率转成类别

保存的记录 `adult:train:00000001` 得到

$$\eta = 0.08743669, \qquad \hat{p} = \frac{1}{1 + e^{-0.08743669}} = 0.52184526.$$

阈值固定为 0.5，因此预测类别为 1。实际标签为 0，这条记录属于假阳性。

年龄的每岁系数为 0.03101，但概率变化还取决于 p：

$$\frac{\partial p}{\partial \text{age}} = p(1 - p) \times 0.03101.$$

全部 6,512 条验证概率已用保存的编码和系数重建，最大绝对差小于 4×10^{-16}。

回归树：先分组，再用组内均值预测

节点 A 按特征 j 与阈值 t 分成左右两组：

$$A_L = \{i : x_{ij} \le t\}, \qquad A_R = \{i : x_{ij} > t\}.$$

选择使下面平方误差最小的分裂：

$$Q(j,t) = \sum_{i \in A_L} (y_i - \bar{y}_{A_L})^2 + \sum_{i \in A_R} (y_i - \bar{y}_{A_R})^2.$$

到达最终叶节点后，预测该节点的均值。均值使组内平方误差最小，已经在常数模型中证明。

本项目最大深度 12，叶节点最少样本数 5。分裂为逐节点贪心选择，见 scikit-learn developers [11]。

分类树：让节点中的类别更集中

节点正类比例为 p_A，基尼不纯度为

$$G(A) = 1 - p_A^2 - (1 - p_A)^2 = 2p_A(1 - p_A).$$

单一类别时 $G = 0$；两类各半时 $G = 0.5$。分裂比较

$$\frac{|A_L|}{|A|} G(A_L) + \frac{|A_R|}{|A|} G(A_R).$$

叶节点输出正类比例。bootstrap 重复抽中的记录按抽样次数参与节点统计。

随机森林平均 120 棵树的预测

回归：$\hat{f}(\mathbf{x}) = \dfrac{1}{120}\sum_{b=1}^{120} \hat{f}_b(\mathbf{x})$。

分类：平均各棵树的正类概率，再用 0.5 阈值分类。

	回归森林	分类森林
抽样	训练记录有放回抽样	训练记录有放回抽样
节点候选特征	全部编码特征	随机抽取约平方根数量
停止条件	深度 12、叶节点至少 5 条	同左

本项目设置为 `max_features=1.0` 与 `"sqrt"`。分类概率平均见 scikit-learn developers [12]。

树之间的相关程度影响平均预测的方差

用简化假设说明：每棵树预测的方差为 σ^2，任意两棵树相关系数为 ρ。

$$\begin{aligned}\mathrm{Var}\left(\frac{1}{B}\sum_b \hat{f}_b\right) &= \frac{B\sigma^2 + B(B-1)\rho\sigma^2}{B^2} \\ &= \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2.\end{aligned}$$

树数增加，第二项减小；树之间仍然相关，第一项不会随树数消失。

这个推导说明树数和树之间的相关程度怎样影响平均预测的方差。

用实际混淆矩阵算出 F1

	预测 0	预测 1
实际 0	4,543	401
实际 1	719	849

Adult 逻辑回归，6,512 条验证记录，阈值 0.5。

精确率问预测为正的有多少正确；召回率问实际正例找到了多少。

$$P = \frac{849}{849 + 401}, \quad R = \frac{849}{849 + 719}.$$

$$F_1 = \frac{2\mathrm{TP}}{2\mathrm{TP} + \mathrm{FP} + \mathrm{FN}}$$

$$= \frac{1698}{1698 + 401 + 719} = 0.6026.$$

平方误差是凸函数

$$\nabla^2 L = 2X^{\mathsf{T}}X.$$

对任意向量 $\mathbf{v}$：

$$\mathbf{v}^{\mathsf{T}}(2X^{\mathsf{T}}X)\mathbf{v} = 2\|X\mathbf{v}\|^2 \geq 0.$$

所以平方误差是凸函数。满列秩时，对非零 $\mathbf{v}$ 严格大于零，解唯一。

正规方程也可写成 $X^{\mathsf{T}}\hat{\mathbf{e}} = 0$：训练残差与每列特征正交。

逻辑回归的 Hessian

由 $\partial p_i/\partial \boldsymbol{\beta} = p_i(1-p_i)\mathbf{x}_i$，令

$$W = \mathrm{diag}\{p_i(1-p_i)\}, \quad D = \mathrm{diag}(0, 1, \ldots, 1),$$

可得

$$\nabla^2 J = \frac{X^{\mathsf{T}} W X}{n_T} + \frac{D}{C n_T}.$$

两项半正定，因此目标为凸函数。程序使用 L-BFGS 迭代，没有显式逐次构造这个 Hessian。

计算脚本对四条固定数值输入做差分检查，梯度与 Hessian 最大误差均小于 2×10^{-11}。

AUC 和 Brier 的计算式

对每一对正例 i 与负例 j，正例概率较高得 1 分，并列得半分：

$$\mathrm{AUC} = \frac{1}{n_+ n_-} \sum_{i \in V_+} \sum_{j \in V_-} \left[\mathbf{1}(\hat{p}_i > \hat{p}_j) + \tfrac{1}{2} \mathbf{1}(\hat{p}_i = \hat{p}_j) \right].$$

Brier 平均概率与标签的平方误差：

$$\mathrm{Brier} = \frac{1}{n_V} \sum_i (y_i - \hat{p}_i)^2.$$

AUC 评价排序；Brier 评价概率误差。概率校准还需要检查不同概率区间与实际频率的对应。

打乱一列，观察预测误差的变化

模型保持不变，随机打乱验证集中的一列，观察预测误差变化：

$$I_j = \mathrm{RMSE}(y_V, \hat{f}(X_V^{\pi_j})) - \mathrm{RMSE}(y_V, \hat{f}(X_V)).$$

分类用打乱前 AUC 减打乱后 AUC。每列重复三次，报告平均值与标准差。

相关特征可以互相替代，打乱一列有时也会偶然降低误差。重要性描述当前模型对该列的依赖，三次重复的标准差描述打乱结果的变化。

数据处理记录

房价	每行均有空白，未全表删行；`None` 类别与空白分开；Id 524 改建年晚于出售年，标记保留。
Adult	原训练文件有 24 条全字段重复额外记录；按非目标字段分组；训练与测试共有 26 组相同字段记录。
NBA	四组姓名与赛季键重复，共八条；年龄或身高不同，未合并。
学生	无空白或全字段重复；源站有生成数据线索，真实抽样未核实。

房价实际下载出处未记录。其他三份 ZIP 与上传清单哈希一致。完整记录见论文附录 D 及质量 CSV。

已完成的检查与后续测试

原固定模型	12 个配置，58 项指标独立复算。
软件组件	100 项通过，主要使用合成夹具。
真实数据接口	35 项通过，使用人工结构化参数。
字段检索	16 道固定题前六条命中，MRR 0.96875。
计算核对	均值与三点 OLS；292 条房价预测、6,512 条概率重建；梯度与 Hessian 核对。
联网问答	DeepSeek API 方案生成质量及 Mac 浏览器完整操作需单独验收。

预测指标来自已保存的十二组基准模型；人工方案与模拟接口测试不代表 DeepSeek 自由问答的准确率。

启动 DeepSeek 联网演示

在项目根目录双击 `TableLab-DeepSeek.command`，或在终端运行：

```
bash TableLab-DeepSeek.command
```

首次按提示输入 DeepSeek API Key；启动器准备 Python 环境并启动网页服务。

浏览器打开 http://127.0.0.1:8765。输入问题后，点击「检索并生成方案」，核对参数，再点击「校验并执行」。

生成新方案需要联网。密钥由终端隐藏输入，默认存入当前用户的 Mac 钥匙串。演示结束在终端按 Control-C。

DeepSeek 生成方案，本机执行计算

步骤	处理内容
本地检索	用字符 TF–IDF 查找字段与方法说明。
API 请求	发送问题、字段名与类型、相关说明及必要的上一轮方案。
方案核对	DeepSeek 返回 JSON；程序检查格式和列名，用户核对筛选条件与算法。
本机执行	筛选原表、计算统计量或训练模型，保存结果与逐条预测。

统计结果、预测误差均由本机程序计算。原始 CSV 不随方案请求整表上传；问题和筛选条件会随请求发送。

API 不可用时，网页显示错误；保存的例题可用 HTML 回放查看。回放只展示既有记录。

现场计算社区均价和房价预测

在网页选择「房价」，输入「CollgCr 社区房屋的平均成交价是多少 ?」

点击「检索并生成方案」，核对 `Neighborhood=CollgCr` 和 `SalePrice` 的均值，再点「校验并执行」。这组数据有 150 条有效记录，平均成交价为 197,965.77 美元。

清空上下文，改用全部房屋记录。「用居住面积和整体质量建立成交价的线性回归。」模型训练后追问：「其他条件不变，改用随机森林。」比较两次的特征、划分、验证误差和运行编号。

远程汇报可共享浏览器窗口；保持网络连接以生成新方案，计算结果和文件在本机查看。

参考文献 I

[1] J. Herzig, P. K. Nowak, T. Müller, F. Piccinno, and J. M. Eisenschlos, "TaPas: Weakly supervised table parsing via pre-training," in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020, pp. 4320–4333.

[2] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, "Retrieval-augmented generation for knowledge-intensive NLP tasks," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474.

[3] Kaggle, "House prices: Advanced regression techniques," Kaggle Competition, n.d.

[4] B. Becker and R. Kohavi, "Adult," UCI Machine Learning Repository, 1996.

[5] justinas, "NBA players," Kaggle Datasets, n.d.

[6] spscientist, "Students performance in exams," Kaggle Datasets, n.d.

[7] scikit-learn developers, "TfidfTransformer," n.d., scikit-learn 1.8 文档；访问日期：2026-10-31. [Online]. Available: https://scikit-learn.org/1.8/modules/generated/sklearn.feature_extraction.text.TfidfTransformer.html

[8] ——, "Linear models," scikit-learn 1.8 documentation, n.d.

[9] L. Breiman, "Random forests," *Machine Learning*, vol. 45, pp. 5–32, 2001.

[10] scikit-learn developers, "Common pitfalls and recommended practices," n.d., 官方文档；访问日期：2026-10-30. [Online]. Available: https://scikit-learn.org/stable/common_pitfalls.html

[11] ——, "Decision trees: Mathematical formulation," n.d., scikit-learn 1.8 文档；访问日期：2026-10-31. [Online]. Available: https://scikit-learn.org/1.8/modules/tree.html

[12] ——, "RandomForestClassifier," n.d., scikit-learn 1.8 文档；访问日期：2026-10-31. [Online]. Available: https://scikit-learn.org/1.8/modules/generated/sklearn.ensemble.RandomForestClassifier.html